# 02. IPCA — Análise da Inflação Brasileira

### IPCA Geral ▪ IBGE/SIDRA ▪ PostgreSQL

Este notebook analisa a evolução do IPCA geral após a validação dos dados realizada em: `00.auditoria_dados.ipynb`

O fluxo operacional esperado é:

```
      IBGE/SIDRA
          |
          v
       pipeline
          |
          v
      PostgreSQL
          |
          v
  00.auditoria_dados
          |
          v
      02.ipca
```

Este notebook assume que:

- o pipeline do IPCA já foi executado;
- a tabela `bcb.ipca_geral` está atualizada;
- a auditoria dos dados foi concluída;
- os dados estão aptos para análise.

Este notebook NÃO executa pipelines e NÃO altera o banco de dados.

---

### Objetivos

1. Entender as principais medidas do IPCA geral.
2. Examinar a cobertura histórica da série.
3. Analisar a inflação mensal.
4. Analisar a inflação acumulada em 12 meses.
5. Identificar períodos de aceleração e desaceleração.
6. Examinar a dinâmica de curto e médio prazo.
7. Explorar observações extremas e diferentes regimes históricos.
8. Preparar uma representação analítica mensal para análises posteriores.

## 1. O que é o IPCA?

- O IPCA é uma das principais medidas da inflação ao consumidor no Brasil.
- A inflação representa a variação do nível de preços ao longo do tempo.
- Neste projeto, o IPCA será analisado inicialmente em nível agregado.

Posteriormente, a análise será decomposta em:

```
IPCA geral
     |
     +-- grupos
     |
     +-- subgrupos
     |
     +-- itens
     |
     +-- subitens
```

Essa separação será importante porque o índice agregado informa quanto os preços variaram, enquanto seus componentes ajudam a entender de onde veio essa variação.

## 2. Medidas utilizadas

A tabela `bcb.ipca_geral` contém diferentes representações da inflação.

### 2.1 Variação mensal

- `indice` → Representa a variação percentual do IPCA no mês.

Exemplo conceitual:

```
janeiro   -> 0,40%
fevereiro -> 0,65%
março     -> 0,30%
```

Essa será uma das principais variáveis para análises econômicas e para futura modelagem.

### 2.2 Acumulado no ano

- `acumulado` → Representa a inflação acumulada desde o início do ano até o mês corrente.

Portanto, a interpretação dessa variável depende da posição do mês dentro do ano.

### 2.3 Acumulado em 12 meses

- `acumulado12m` → Representa a inflação acumulada nos últimos 12 meses.

Essa medida oferece uma visão mais persistente da dinâmica inflacionária do que a variação de um único mês.

### 2.4 Número-índice

- `nindice` → O número-índice representa o nível acumulado do índice de preços em relação à base metodológica da série.

Diferentemente da variação mensal, o número-índice representa um nível, e não uma taxa de variação mensal.

## 3. Configuração do ambiente

```python
from pathlib import Path
import sys

PROJECT_ROOT = Path.cwd().resolve()

if PROJECT_ROOT.name == "notebooks":
    PROJECT_ROOT = PROJECT_ROOT.parent
```

```
if str(PROJECT_ROOT) not in sys.path:
    sys.path.insert(0, str(PROJECT_ROOT))

print("Project root:", PROJECT_ROOT)
```

```
Project root: /home/moacir/projects/ml/analytics/inflation
```

### 4. Importações

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from src.database.connection import engine

pd.set_option("display.max_columns", None)
pd.set_option("display.max_rows", 100)
pd.set_option("display.width", 160)
pd.set_option("display.float_format", "{:.4f}".format)
```

### 5. Carregar IPCA geral do PostgreSQL

O notebook apenas consome a tabela já atualizada pelo pipeline.

```
ipca = pd.read_sql(
    """
    SELECT
        date,
        indice,
        nindice,
        acumulado,
        acumulado12m
    FROM bcb.ipca_geral
    ORDER BY date;
    """,
    engine,
)
```

### 5.1 Padronizar datas

Antes de qualquer operação temporal, garantimos explicitamente que a coluna `date` esteja em formato datetime e que a base esteja ordenada.

```
ipca["date"] = pd.to_datetime(
    ipca["date"]
)

ipca = (
    ipca
    .sort_values("date")
    .reset_index(drop=True)
)

ipca.tail()
```

| | date | indice | nindice | acumulado | acumulado12m |
|---|---|---|---|---|---|
| 556 | 2026-04-01 | 0.6700 | 7596.0900 | 2.6000 | 4.3900 |
| 557 | 2026-05-01 | 0.5800 | 7640.1500 | 3.2000 | 4.7200 |
| 558 | 2026-06-01 | 0.1600 | 7652.3700 | 3.3600 | 4.6400 |
| 559 | 2026-07-01 | 0.0700 | 7657.7300 | 3.4400 | 4.4400 |
| 560 | 2026-08-01 | -0.3200 | 7633.2300 | 3.1100 | 4.2200 |

## 6. Cobertura histórica

```
resumo_serie = pd.DataFrame(
    [
        {
            "serie": "IPCA Geral",
            "inicio": ipca["date"].min(),
            "fim": ipca["date"].max(),
            "observacoes": len(ipca),
        }
    ]
)

resumo_serie
```

| | serie | inicio | fim | observacoes |
|---|---|---|---|---|
| 0 | IPCA Geral | 1979-12-01 | 2026-08-01 | 561 |

## 7. Observações mais recentes

```
ipca.tail(12)
```

| | date | indice | nindice | acumulado | acumulado12m |
|---|---|---|---|---|---|
| 549 | 2025-09-01 | 0.4800 | 7359.0600 | 3.6400 | 5.1700 |
| 550 | 2025-10-01 | 0.0900 | 7365.6800 | 3.7300 | 4.6800 |
| 551 | 2025-11-01 | 0.1800 | 7378.9400 | 3.9200 | 4.4600 |
| 552 | 2025-12-01 | 0.3300 | 7403.2900 | 4.2600 | 4.2600 |
| 553 | 2026-01-01 | 0.3300 | 7427.7200 | 0.3300 | 4.4400 |
| 554 | 2026-02-01 | 0.7000 | 7479.7100 | 1.0300 | 3.8100 |
| 555 | 2026-03-01 | 0.8800 | 7545.5300 | 1.9200 | 4.1400 |
| 556 | 2026-04-01 | 0.6700 | 7596.0900 | 2.6000 | 4.3900 |
| 557 | 2026-05-01 | 0.5800 | 7640.1500 | 3.2000 | 4.7200 |
| 558 | 2026-06-01 | 0.1600 | 7652.3700 | 3.3600 | 4.6400 |
| 559 | 2026-07-01 | 0.0700 | 7657.7300 | 3.4400 | 4.4400 |
| 560 | 2026-08-01 | -0.3200 | 7633.2300 | 3.1100 | 4.2200 |

## 8. Estatísticas descritivas

Como a série atravessa diferentes regimes inflacionários, estatísticas calculadas sobre todo o histórico devem ser interpretadas com cautela.

```
ipca[
    [
        "indice",
        "nindice",
        "acumulado",
        "acumulado12m",
    ]
].describe()
```

| | indice | nindice | acumulado | acumulado12m |
|---|---|---|---|---|
| count | 560.0000 | 561.0000 | 560.0000 | 549.0000 |
| mean | 5.5008 | 2483.7638 | 88.9647 | 291.2646 |
| std | 10.5256 | 2289.7936 | 256.3168 | 840.6683 |
| min | -0.6800 | 0.0000 | -0.1600 | 1.6500 |
| 25% | 0.3600 | 0.1478 | 2.4200 | 4.9400 |
| 50% | 0.7000 | 2165.2900 | 4.7150 | 7.3900 |
| 75% | 6.3700 | 4059.8600 | 40.1625 | 115.0300 |
| max | 82.3900 | 7657.7300 | 2477.1500 | 6821.3100 |

---

## PARTE I — INFLAÇÃO MENSAL

### 9. Evolução histórica da variação mensal

A coluna `indice` representa a inflação observada em cada mês.

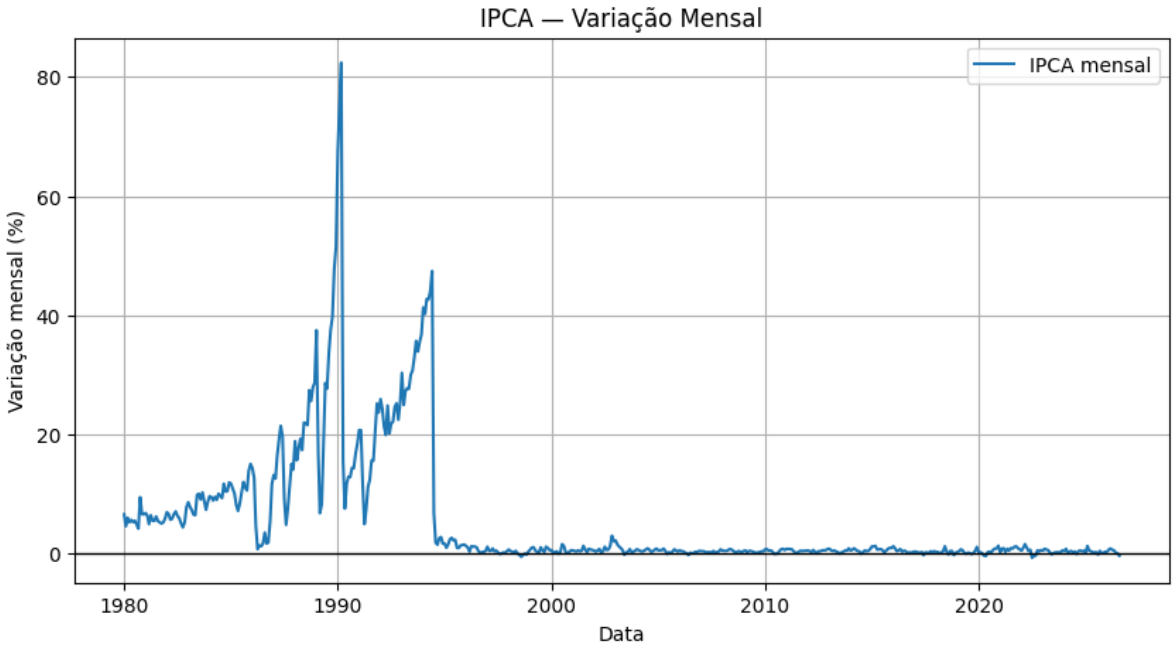
```
plt.figure(figsize=(10, 5))

plt.plot(
    ipca["date"],
    ipca["indice"],
    label="IPCA mensal",
)

plt.axhline(
    0,
    color="black",
    linewidth=1,
)

plt.title("IPCA - Variação Mensal")
plt.xlabel("Data")
plt.ylabel("Variação mensal (%)")
plt.grid(True)
plt.legend()

plt.show()
```




## 10. Diferentes regimes históricos

O gráfico completo pode ser dominado visualmente por períodos históricos com inflação muito elevada.

Isso significa que oscilações recentes relativamente pequenas podem ficar visualmente comprimidas.

Portanto, além do histórico completo, analisaremos separadamente períodos mais recentes.

### 10.1 IPCA desde 1995

```
ipca_pos_1995 = ipca[ipca["date"] >= "1995-01-01"].copy()

plt.figure(figsize=(10, 5))

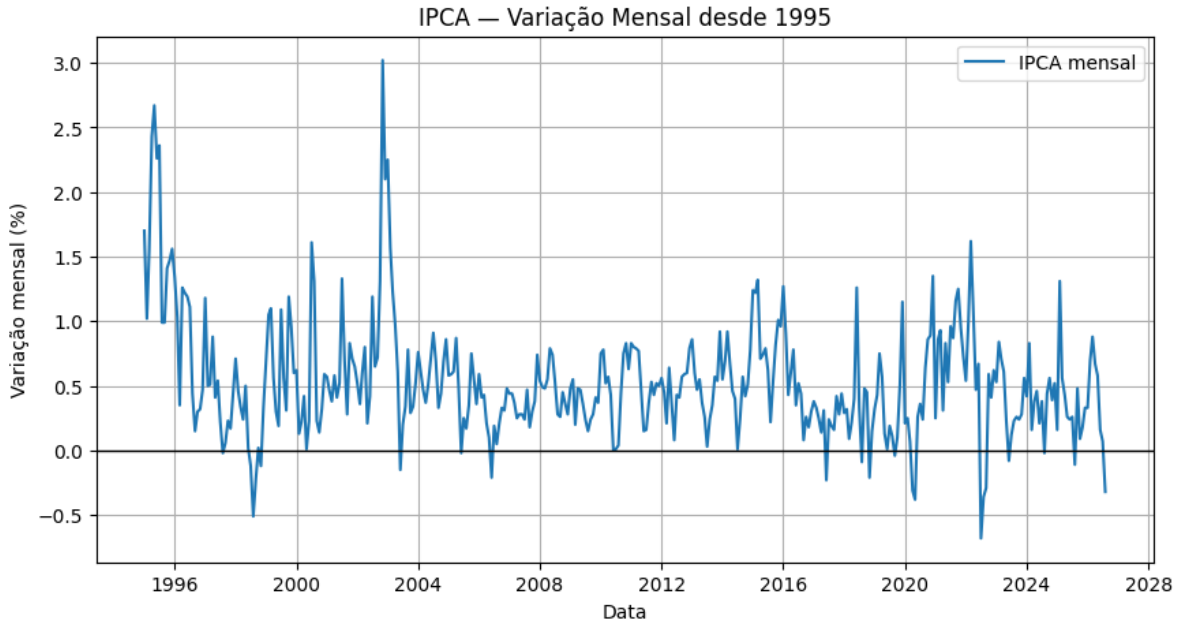
plt.plot(
    ipca_pos_1995["date"],
    ipca_pos_1995["indice"],
    label="IPCA mensal",
)

plt.axhline(
```

```
    0,
    color="black",
    linewidth=1,
)

plt.title("IPCA - Variação Mensal desde 1995")
plt.xlabel("Data")
plt.ylabel("Variação mensal (%)")
plt.grid(True)
plt.legend()

plt.show()
```




### 10.2 Últimos 10 anos

```
data_inicio_10a = (
    ipca["date"].max()
    - pd.DateOffset(years=10)
)

ipca_10a = ipca[
    ipca["date"] >= data_inicio_10a
```

```
].copy()

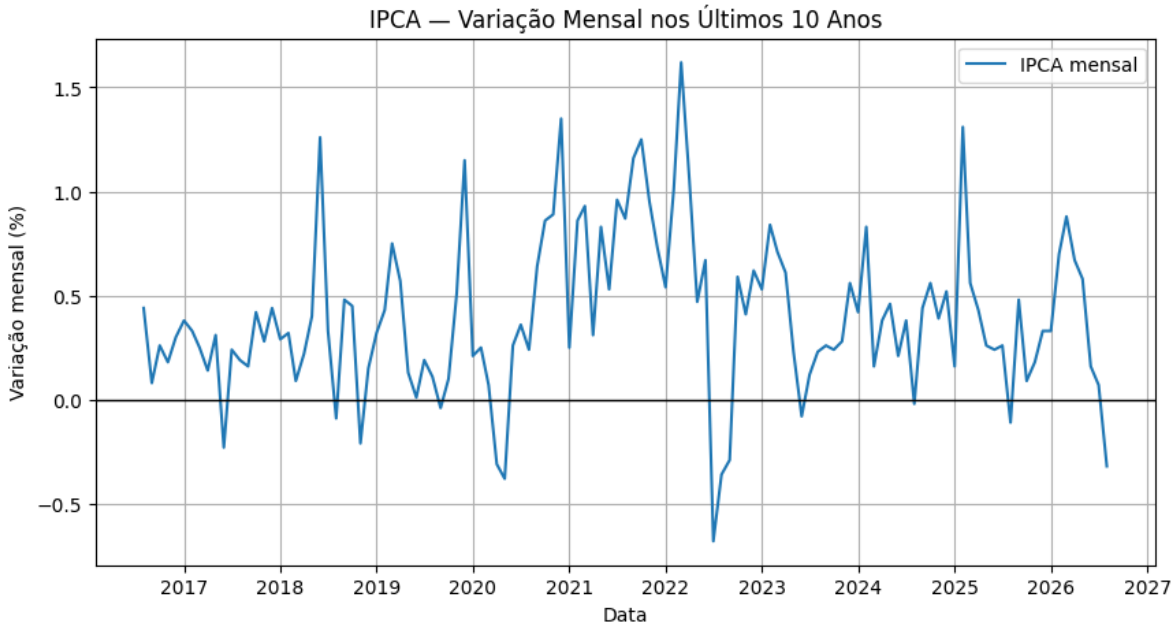
plt.figure(figsize=(10, 5))

plt.plot(
    ipca_10a["date"],
    ipca_10a["indice"],
    label="IPCA mensal",
)

plt.axhline(
    0,
    color="black",
    linewidth=1,
)

plt.title("IPCA - Variação Mensal nos Últimos 10 Anos")
plt.xlabel("Data")
plt.ylabel("Variação mensal (%)")
plt.grid(True)
plt.legend()

plt.show()
```



## 11. Distribuição histórica da inflação mensal

O histograma mostra quantas vezes determinadas faixas de inflação mensal apareceram ao longo do histórico.

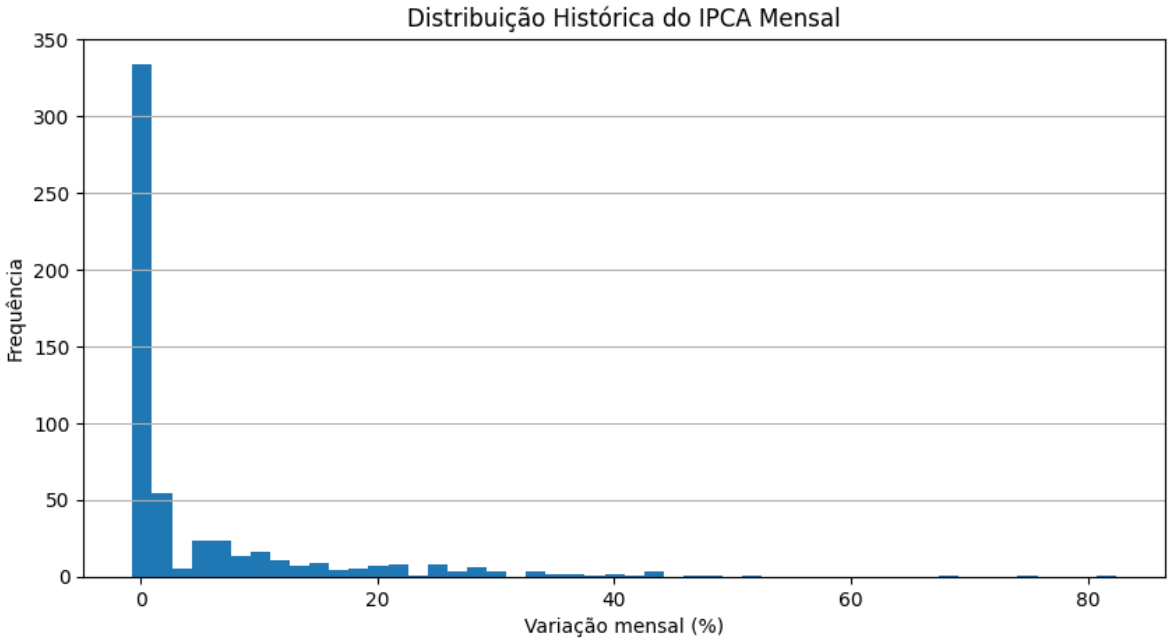
Assim como ocorreu com a SELIC, essa distribuição combina diferentes regimes econômicos e não deve ser interpretada como uma distribuição única e estável no tempo.

```
plt.figure(figsize=(10, 5))

plt.hist(
    ipca["indice"].dropna(),
    bins=50,
)

plt.title("Distribuição Histórica do IPCA Mensal")
plt.xlabel("Variação mensal (%)")
plt.ylabel("Frequência")
plt.grid(True, axis="y")

plt.show()
```



## 12. Observações mensais extremas

Os maiores e menores valores históricos são úteis para:

- identificar diferentes regimes de inflação;
- contextualizar outliers;
- evitar tratar automaticamente valores extremos como erro;
- compreender futuras dificuldades de modelagem.

### Maiores variações mensais

```
ipca.nlargest(10, "indice",)[
    ["date", "indice", "acumulado12m"]
]
```

| | date | indice | acumulado12m |
|---|---|---|---|
| 123 | 1990-03-01 | 82.3900 | 6390.5300 |
| 122 | 1990-02-01 | 75.7300 | 3701.2900 |
| 121 | 1990-01-01 | 67.5500 | 2426.1200 |
| 120 | 1989-12-01 | 51.5000 | 1972.9100 |
| 119 | 1989-11-01 | 47.8200 | 1660.9500 |
| 174 | 1994-06-01 | 47.4300 | 4922.6000 |
| 173 | 1994-05-01 | 44.0300 | 4331.1900 |
| 171 | 1994-03-01 | 42.7500 | 3417.3900 |
| 172 | 1994-04-01 | 42.6800 | 3828.4900 |
| 169 | 1994-01-01 | 41.3100 | 2693.8400 |

### Menores variações mensais

```
ipca.nsmallest(10, "indice",)[
    ["date", "indice", "acumulado12m"]
]
```

| | date | indice | acumulado12m |
|---|---|---|---|
| 511 | 2022-07-01 | -0.6800 | 10.0700 |
| 224 | 1998-08-01 | -0.5100 | 2.5500 |
| 485 | 2020-05-01 | -0.3800 | 1.8800 |
| 512 | 2022-08-01 | -0.3600 | 8.7300 |
| 560 | 2026-08-01 | -0.3200 | 4.2200 |

| | date | indice | acumulado12m |
|---|---|---|---|
| 484 | 2020-04-01 | -0.3100 | 2.4000 |
| 513 | 2022-09-01 | -0.2900 | 7.1700 |
| 450 | 2017-06-01 | -0.2300 | 3.0000 |
| 225 | 1998-09-01 | -0.2200 | 2.2700 |
| 318 | 2006-06-01 | -0.2100 | 4.0300 |

## PARTE II — INFLAÇÃO EM 12 MESES

### 13. Evolução histórica

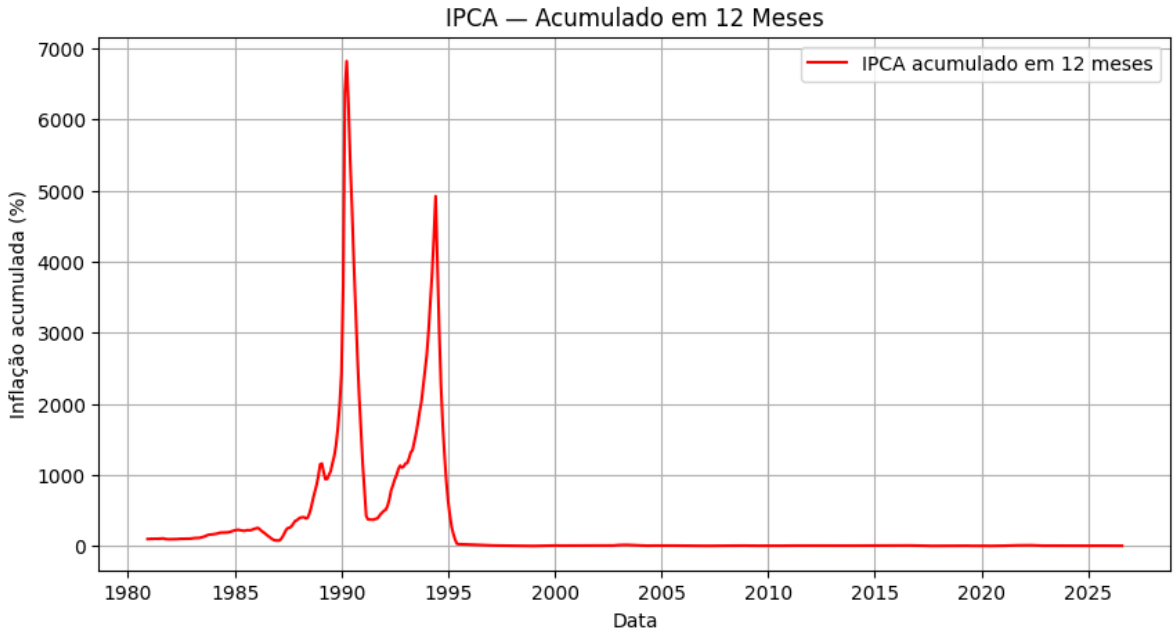
A inflação acumulada em 12 meses apresenta uma visão mais persistente do processo inflacionário que a variação mensal isolada.

```
plt.figure(figsize=(10, 5))

plt.plot(
    ipca["date"],
    ipca["acumulado12m"],
    color="red",
    label="IPCA acumulado em 12 meses",
)

plt.title("IPCA - Acumulado em 12 Meses")
plt.xlabel("Data")
plt.ylabel("Inflação acumulada (%)")
plt.grid(True)
plt.legend()

plt.show()
```



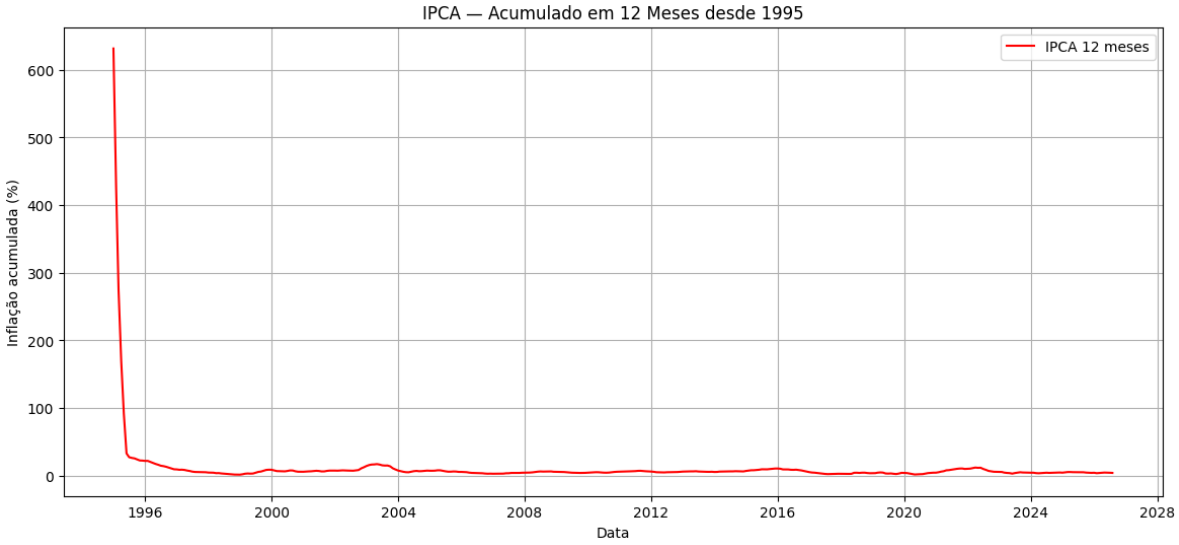

### 14. Acumulado em 12 meses desde 1995

```
plt.figure(figsize=(14, 6))

plt.plot(
    ipca_pos_1995["date"],
    ipca_pos_1995["acumulado12m"],
    color="red",
    label="IPCA 12 meses",
)

plt.title("IPCA - Acumulado em 12 Meses desde 1995")
plt.xlabel("Data")
plt.ylabel("Inflação acumulada (%)")
plt.grid(True)
plt.legend()

plt.show()
```



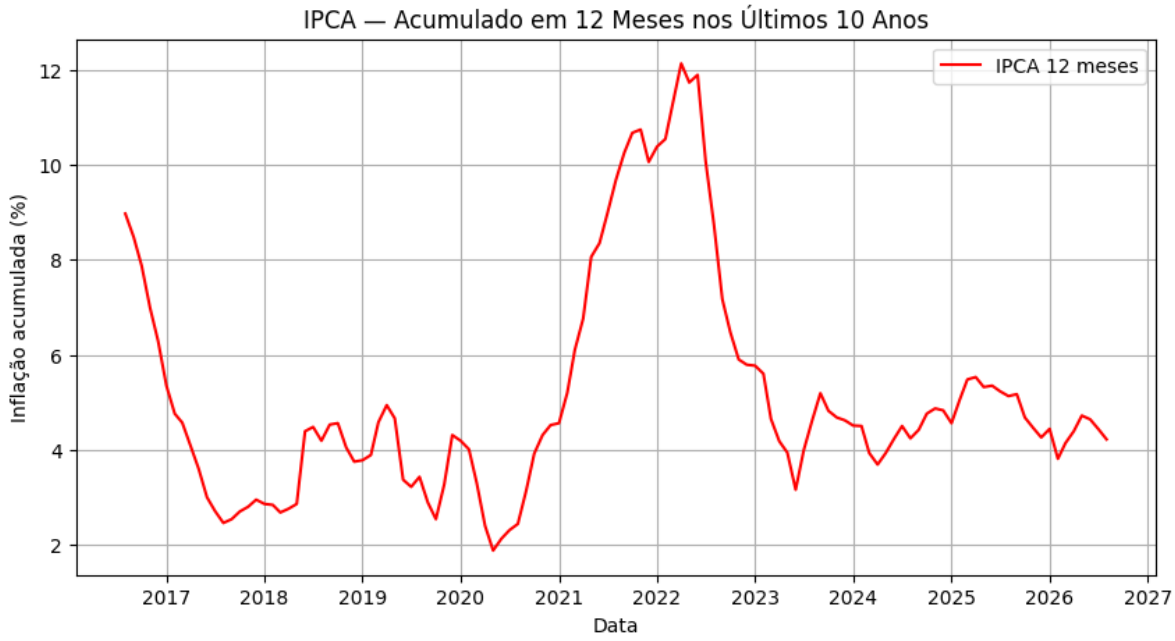

### 15. Evolução recente do acumulado em 12 meses

```
plt.figure(figsize=(10, 5))

plt.plot(
    ipca_10a["date"],
    ipca_10a["acumulado12m"],
    color="red",
    label="IPCA 12 meses",
)

plt.title("IPCA - Acumulado em 12 Meses nos Últimos 10 Anos")
plt.xlabel("Data")
plt.ylabel("Inflação acumulada (%)")
plt.grid(True)
plt.legend()

plt.show()
```




---

## PARTE III — ACELERAÇÃO E DESACELERAÇÃO

### 16. Variação da inflação mensal

Calculamos:

$$\Delta IPCA_t = IPCA_t - IPCA_{t-1}$$

- Valores positivos → indicam que a inflação mensal foi maior que no mês anterior.
- Valores negativos → indicam redução da inflação mensal em relação ao mês anterior.

```
ipca["delta_indice"] = (ipca["indice"].diff())

ipca[
    [
        "date",
        "indice",
        "delta_indice",
    ]
].tail(8)
```

| | date | indice | delta_indice |
|---|---|---|---|
| 553 | 2026-01-01 | 0.3300 | 0.0000 |
| 554 | 2026-02-01 | 0.7000 | 0.3700 |
| 555 | 2026-03-01 | 0.8800 | 0.1800 |
| 556 | 2026-04-01 | 0.6700 | -0.2100 |
| 557 | 2026-05-01 | 0.5800 | -0.0900 |
| 558 | 2026-06-01 | 0.1600 | -0.4200 |
| 559 | 2026-07-01 | 0.0700 | -0.0900 |
| 560 | 2026-08-01 | -0.3200 | -0.3900 |

### 17. Variação da inflação acumulada em 12 meses

A diferença mensal do acumulado em 12 meses permite observar se essa medida está acelerando ou desacelerando.

```
ipca["delta_12m"] = (ipca["acumulado12m"].diff())

ipca[
    [
        "date",
        "acumulado12m",
        "delta_12m",
    ]
].tail(8)
```

| | date | acumulado12m | delta_12m |
|---|---|---|---|
| 553 | 2026-01-01 | 4.4400 | 0.1800 |
| 554 | 2026-02-01 | 3.8100 | -0.6300 |
| 555 | 2026-03-01 | 4.1400 | 0.3300 |
| 556 | 2026-04-01 | 4.3900 | 0.2500 |
| 557 | 2026-05-01 | 4.7200 | 0.3300 |
| 558 | 2026-06-01 | 4.6400 | -0.0800 |
| 559 | 2026-07-01 | 4.4400 | -0.2000 |
| 560 | 2026-08-01 | 4.2200 | -0.2200 |

### 18. Classificação simples da dinâmica de 12 meses

Criamos uma classificação descritiva:

$\Delta_{12m} > 0 \rightarrow$ aceleração
$\Delta_{12m} < 0 \rightarrow$ desaceleração
$\Delta_{12m} = 0 \rightarrow$ estabilidade

Essa classificação não representa previsão ou causalidade.

```
ipca["dinamica_12m"] = np.select(
    [
        ipca["delta_12m"] > 0,
        ipca["delta_12m"] < 0,
    ],
    [
        "aceleracao",
        "desaceleracao",
    ],
    default="estabilidade",
)

ipca[
    [
        "date",
        "acumulado12m",
        "delta_12m",
        "dinamica_12m",
    ]
].tail(12)
```

| | date | acumulado12m | delta_12m | dinamica_12m |
|---|---|---|---|---|
| 549 | 2025-09-01 | 5.1700 | 0.0400 | aceleracao |
| 550 | 2025-10-01 | 4.6800 | -0.4900 | desaceleracao |
| 551 | 2025-11-01 | 4.4600 | -0.2200 | desaceleracao |
| 552 | 2025-12-01 | 4.2600 | -0.2000 | desaceleracao |
| 553 | 2026-01-01 | 4.4400 | 0.1800 | aceleracao |
| 554 | 2026-02-01 | 3.8100 | -0.6300 | desaceleracao |
| 555 | 2026-03-01 | 4.1400 | 0.3300 | aceleracao |
| 556 | 2026-04-01 | 4.3900 | 0.2500 | aceleracao |
| 557 | 2026-05-01 | 4.7200 | 0.3300 | aceleracao |
| 558 | 2026-06-01 | 4.6400 | -0.0800 | desaceleracao |
| 559 | 2026-07-01 | 4.4400 | -0.2000 | desaceleracao |
| 560 | 2026-08-01 | 4.2200 | -0.2200 | desaceleracao |

### 19. Frequência da dinâmica de 12 meses

```
ipca["dinamica_12m"].value_counts()
```

```
dinamica_12m
aceleracao       293
desaceleracao    254
estabilidade      14
Name: count, dtype: int64
```

### 20. Evolução recente da aceleração/desaceleração

```
ipca_dinamica_recente = (ipca[ipca["date"] >= data_inicio_10a].copy())

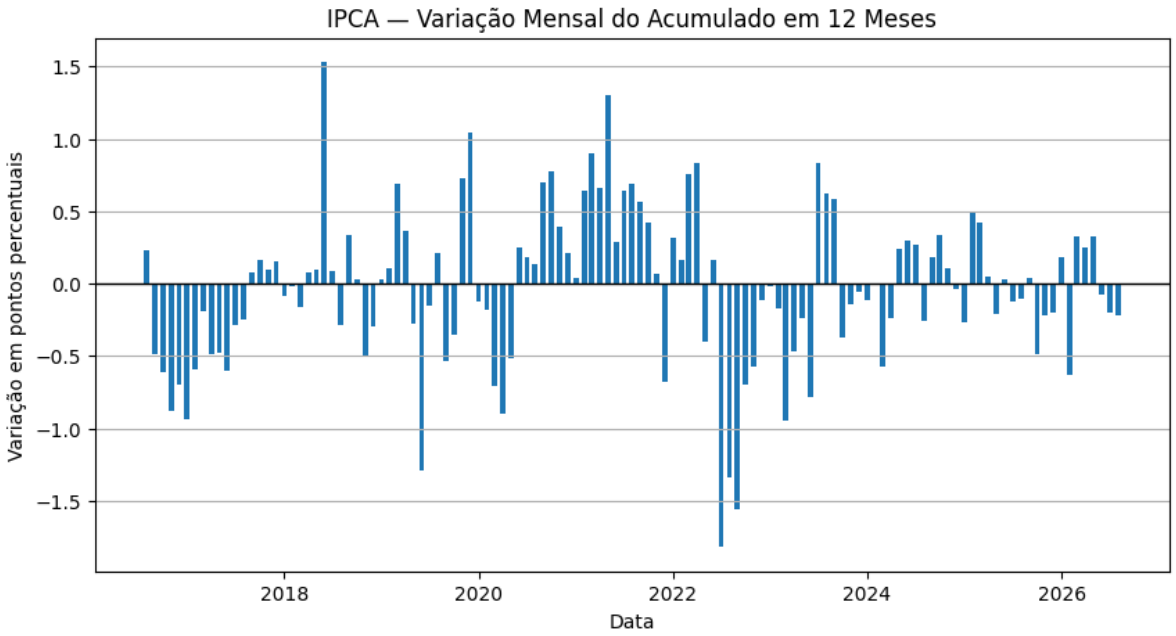
plt.figure(figsize=(10, 5))

plt.bar(
    ipca_dinamica_recente["date"],
    ipca_dinamica_recente["delta_12m"],
    width=20,
)

plt.axhline(
    0,
    color="black",
    linewidth=1,
)

plt.title(
    "IPCA - Variação Mensal do Acumulado em 12 Meses"
)
plt.xlabel("Data")
plt.ylabel("Variação em pontos percentuais")
plt.grid(True, axis="y")

plt.show()
```




---

## PARTE IV — DINÂMICA DE CURTO E MÉDIO PRAZO

### 21. Médias móveis da inflação mensal

Calculamos médias móveis simples da variação mensal:

$mm3 \rightarrow$ média dos últimos 3 meses
$mm6 \rightarrow$ média dos últimos 6 meses
$mm12 \rightarrow$ média dos últimos 12 meses

Essas medidas suavizam oscilações mensais e ajudam a visualizar a direção recente da inflação.

Importante: $mm12$ ! = acumulado12m

A média móvel de 12 meses é uma média aritmética das variações mensais. O acumulado em 12 meses representa uma medida acumulada da inflação.

```
ipca["mm3"] = (ipca["indice"].rolling(3).mean())

ipca["mm6"] = (ipca["indice"].rolling(6).mean())

ipca["mm12"] = (ipca["indice"].rolling(12).mean())
```

### 22. Médias móveis no período recente

```
ipca_medias_recente = ipca[ipca["date"] >= data_inicio_10a].copy()

plt.figure(figsize=(14, 6))

plt.plot(
    ipca_medias_recente["date"],
    ipca_medias_recente["indice"],
    alpha=0.35,
    label="IPCA mensal",
)

plt.plot(
    ipca_medias_recente["date"],
    ipca_medias_recente["mm3"],
    label="MM3",
)

plt.plot(
    ipca_medias_recente["date"],
    ipca_medias_recente["mm6"],
    label="MM6",
)

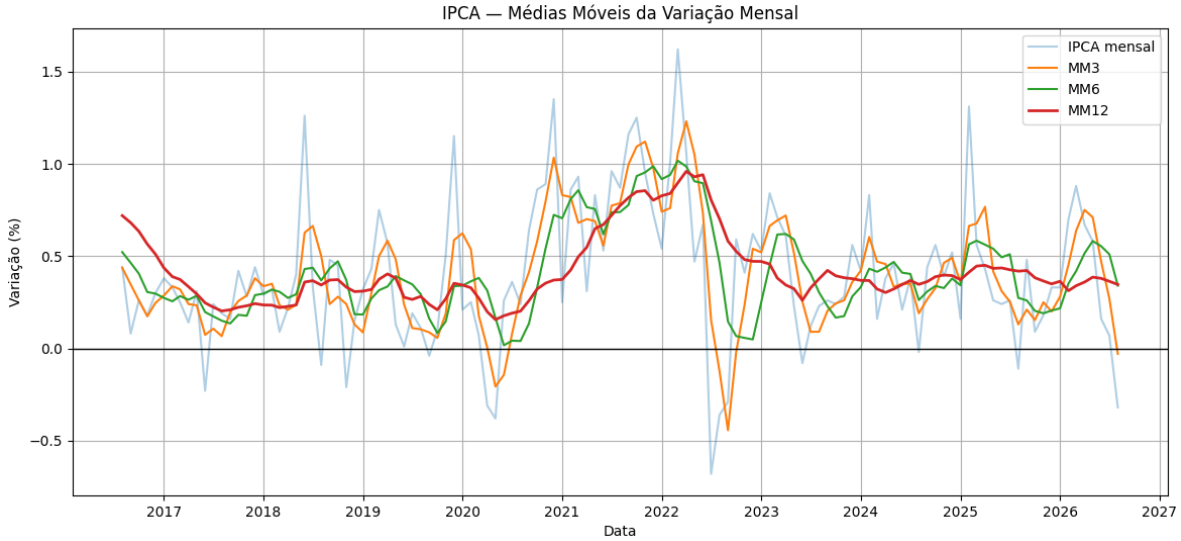
plt.plot(
    ipca_medias_recente["date"],
    ipca_medias_recente["mm12"],
    linewidth=2,
    label="MM12",
)

plt.axhline(
    0,
    color="black",
    linewidth=1,
)

plt.title("IPCA - Médias Móveis da Variação Mensal")
plt.xlabel("Data")
plt.ylabel("Variação (%)")
plt.grid(True)
```

```
plt.legend()

plt.show()
```




## 23. Heatmap dos últimos 24 meses

O heatmap facilita a leitura de períodos recentes de:

- inflação mensal mais elevada;
- inflação mensal mais baixa;
- deflação.

Mantemos `date` como datetime no DataFrame principal e criamos apenas um rótulo específico para visualização.

```
ipca_24m = (
    ipca[
        ["date", "indice"]
    ]
    .tail(24)
    .copy()
)

ipca_24m["periodo"] = (
    ipca_24m["date"]
```

```
    .dt.strftime("%Y-%m")
)

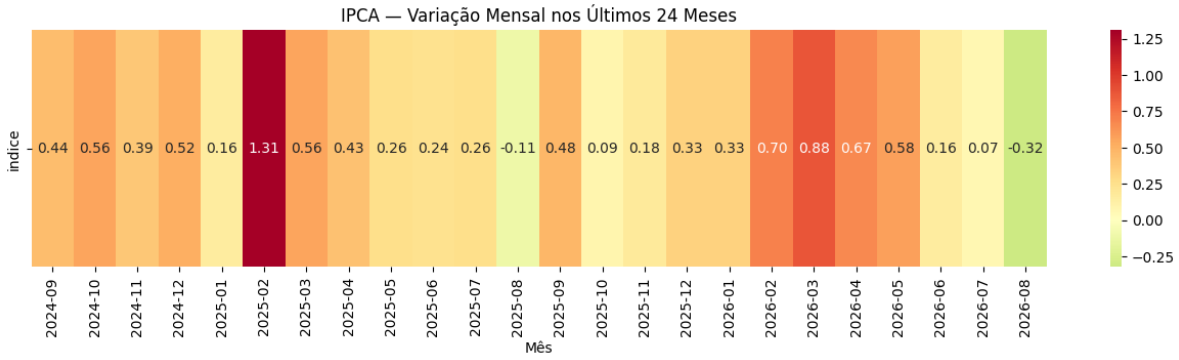
heatmap_data = (
    ipca_24m
    .set_index("periodo")[["indice"]]
    .T
)

plt.figure(figsize=(16, 3))

sns.heatmap(
    heatmap_data,
    cmap="RdYlGn_r",
    center=0,
    annot=True,
    fmt=".2f",
)

plt.title(
    "IPCA - Variação Mensal nos Últimos 24 Meses"
)
plt.xlabel("Mês")
plt.ylabel("")

plt.show()
```



# PARTE V — NÚMERO-ÍNDICE

## 24. Evolução do número-índice

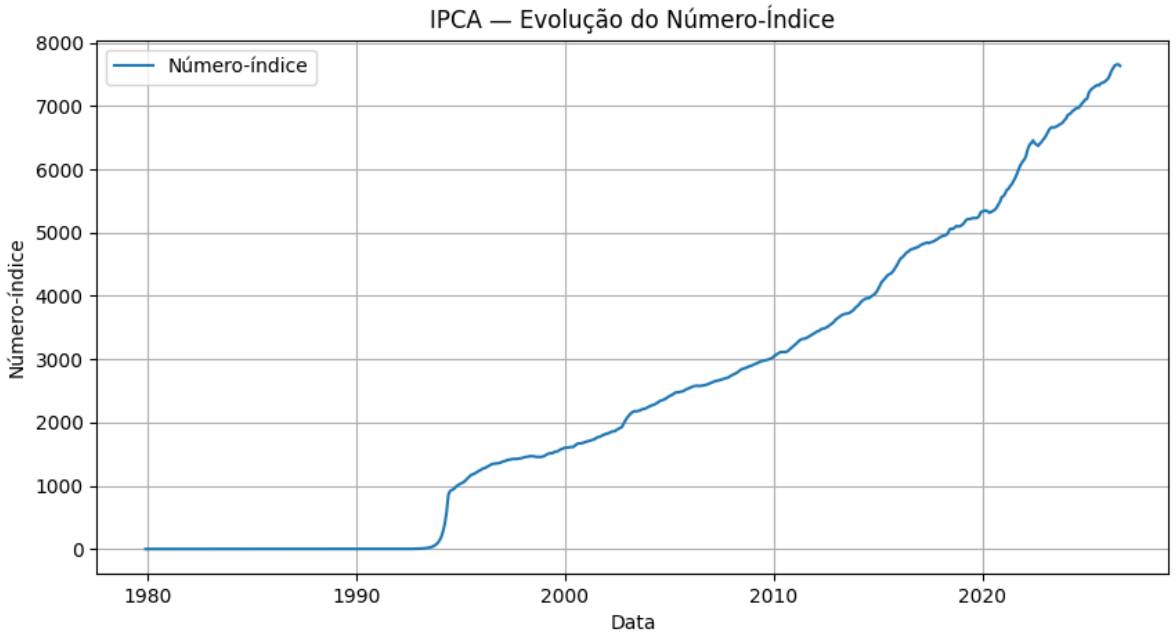
Enquanto a variação mensal mede a mudança de preços em determinado mês, o número-índice representa o nível acumulado da série.

```
plt.figure(figsize=(10, 5))

plt.plot(
    ipca["date"],
    ipca["nindice"],
    label="Número-índice",
)

plt.title("IPCA - Evolução do Número-Índice")
plt.xlabel("Data")
plt.ylabel("Número-índice")
plt.grid(True)
plt.legend()

plt.show()
```



### 25. Relação entre número-índice e variação mensal

Conceitualmente:

```
número-índice
     |
     +--> nível da série de preços

variação mensal
     |
     +--> mudança percentual daquele nível
```

Essa distinção será importante quando definirmos o target de previsão.

Para forecasting da inflação, em geral estaremos interessados em prever uma taxa de variação futura, e não simplesmente o nível nominal do número-índice.

---

## PARTE VI — COMPARAÇÃO DA DINÂMICA RECENTE

### 26. Inflação mensal e acumulada em 12 meses

As duas medidas possuem escalas e interpretações diferentes.

Para evitar confusão visual, apresentamos as séries em painéis separados, mas utilizando o mesmo eixo temporal.

```
fig, axes = plt.subplots(
    2,
    1,
    figsize=(10, 7),
    sharex=True,
)

axes[0].plot(
    ipca_10a["date"],
    ipca_10a["indice"],
    label="IPCA mensal",
)

axes[0].axhline(
```

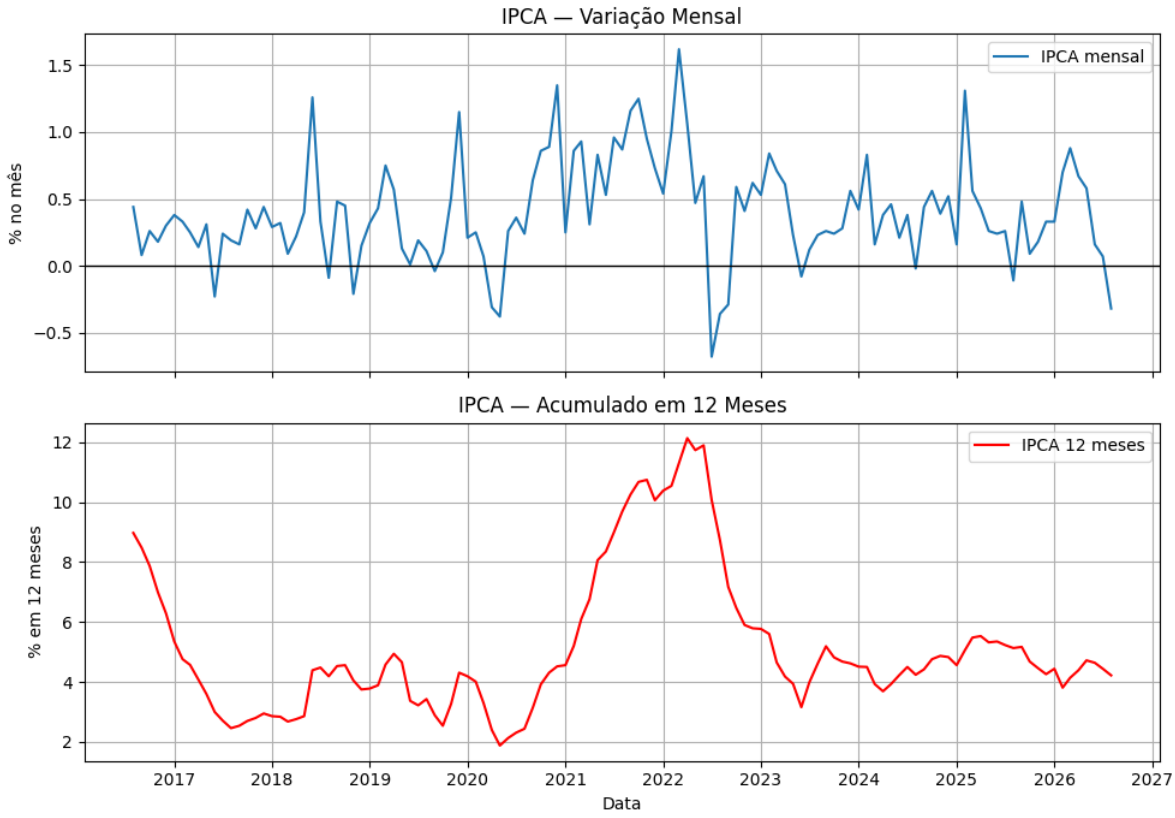
```
    0,
    color="black",
    linewidth=1,
)

axes[0].set_title(
    "IPCA - Variação Mensal"
)
axes[0].set_ylabel("% no mês")
axes[0].grid(True)
axes[0].legend()


axes[1].plot(
    ipca_10a["date"],
    ipca_10a["acumulado12m"],
    color="red",
    label="IPCA 12 meses",
)

axes[1].set_title(
    "IPCA - Acumulado em 12 Meses"
)
axes[1].set_xlabel("Data")
axes[1].set_ylabel("% em 12 meses")
axes[1].grid(True)
axes[1].legend()

plt.tight_layout()
plt.show()
```




---

## PARTE VII — PREPARAÇÃO PARA ANÁLISES POSTERIORES

### 27. Estrutura mensal

Diferentemente da SELIC, o IPCA geral já possui naturalmente frequência mensal.

Portanto:

```
IPCA
 |
 +--> uma observação por mês
```

Isso será a referência temporal para integrar posteriormente:

```
IPCA
 +
SELIC Meta mensal
 +
SELIC Over mensal
 +
componentes do IPCA
```

A existência de um calendário mensal comum será fundamental para a futura construção das features.

### 28. Dataset analítico preliminar

Criamos uma visão reduzida da série contendo algumas variáveis derivadas exploradas neste notebook.

```
ipca_analitico = ipca[
    [
        "date",
        "indice",
        "nindice",
        "acumulado",
        "acumulado12m",
        "delta_indice",
        "delta_12m",
        "dinamica_12m",
        "mm3",
        "mm6",
        "mm12",
    ]
].copy()

ipca_analitico.tail(12)
```

| | date | indice | nindice | acumulado | acumulado12m | delta_indice | delta_12m | dinamica_ |
|---|---|---|---|---|---|---|---|---|
| 549 | 2025-09-01 | 0.4800 | 7359.0600 | 3.6400 | 5.1700 | 0.5900 | 0.0400 | aceleracao |
| 550 | 2025-10-01 | 0.0900 | 7365.6800 | 3.7300 | 4.6800 | -0.3900 | -0.4900 | desacelerac |
| 551 | 2025-11-01 | 0.1800 | 7378.9400 | 3.9200 | 4.4600 | 0.0900 | -0.2200 | desacelerac |
| 552 | 2025-12-01 | 0.3300 | 7403.2900 | 4.2600 | 4.2600 | 0.1500 | -0.2000 | desacelerac |
| 553 | 2026-01-01 | 0.3300 | 7427.7200 | 0.3300 | 4.4400 | 0.0000 | 0.1800 | aceleracao |

| | date | indice | nindice | acumulado | acumulado12m | delta_indice | delta_12m | dinamica_ |
|---|---|---|---|---|---|---|---|---|
| 554 | 2026-02-01 | 0.7000 | 7479.7100 | 1.0300 | 3.8100 | 0.3700 | -0.6300 | desaceleraç |
| 555 | 2026-03-01 | 0.8800 | 7545.5300 | 1.9200 | 4.1400 | 0.1800 | 0.3300 | aceleracao |
| 556 | 2026-04-01 | 0.6700 | 7596.0900 | 2.6000 | 4.3900 | -0.2100 | 0.2500 | aceleracao |
| 557 | 2026-05-01 | 0.5800 | 7640.1500 | 3.2000 | 4.7200 | -0.0900 | 0.3300 | aceleracao |
| 558 | 2026-06-01 | 0.1600 | 7652.3700 | 3.3600 | 4.6400 | -0.4200 | -0.0800 | desaceleraç |
| 559 | 2026-07-01 | 0.0700 | 7657.7300 | 3.4400 | 4.4400 | -0.0900 | -0.2000 | desaceleraç |
| 560 | 2026-08-01 | -0.3200 | 7633.2300 | 3.1100 | 4.2200 | -0.3900 | -0.2200 | desaceleraç |

**Importante**

`ipca_analitico` ainda NÃO representa o dataset final de machine learning.

Variáveis como:

```
mm3
mm6
mm12
delta_indice
delta_12m
```

são transformações exploratórias.

Antes de utilizá-las em um modelo será necessário definir:

- qual será o target;
- qual será o horizonte de previsão;
- quais informações estavam disponíveis no momento da previsão;
- quais defasagens serão utilizadas;
- como será realizado o split temporal;
- como evitar leakage.

### 29. Target futuro de modelagem

Uma das decisões mais importantes da próxima fase será definir exatamente o que queremos prever.

Algumas possibilidades:

**IPCA do próximo mês** $\rightarrow \qquad y_t = IPCA_{t+1}$

**IPCA três meses à frente** $\rightarrow$ $y_t = IPCA_{t+3}$

**Inflação acumulada futura** $\rightarrow$ $y_t = IPCA12M_{t+h}$

Cada definição gera um problema de machine learning diferente.

Portanto, ainda não deslocamos o target neste notebook.

### 30. Defasagens futuras

Posteriormente, poderemos construir features como:

$$X_t = [IPCA_{t-1}, IPCA_{t-2}, IPCA_{t-3}, SELIC_{t-1}, SELIC_{t-2}, ...]$$

Essa estrutura transforma a série temporal em um problema supervisionado.

Um cuidado será fundamental:

```
informação disponível até t
         |
         v
       modelo
         |
         v
previsão de t+h
```

Nenhuma informação posterior a `t` poderá entrar nas features utilizadas para produzir a previsão.

---

### 31. Próxima decomposição do IPCA

Até este ponto analisamos apenas:

```
             IPCA geral
                 |
                 v
         comportamento agregado
```

Essa análise responde:

Quanto a inflação variou?

Os próximos notebooks acrescentarão uma segunda pergunta:

Quais componentes explicam essa variação?

Utilizaremos:

```
IPCA geral
     |
     +--> grupos
            |
            +--> subgrupos
                    |
                    +--> itens
                            |
                            +--> subitens
```

Isso permitirá estudar:

- contribuição dos grupos;
- composição da inflação;
- disseminação dos aumentos de preços;
- mudanças na estrutura inflacionária;
- potenciais features para forecasting.

## 32. Conclusões

Este notebook estabeleceu a visão agregada da inflação brasileira utilizada no projeto.

### IPCA mensal

Representa a variação observada dos preços em cada mês e apresenta grande diferença de comportamento entre períodos históricos.

### IPCA acumulado em 12 meses

Oferece uma visão mais persistente da dinâmica inflacionária e permite observar fases de aceleração e desaceleração.

### Regimes históricos

O histórico completo inclui períodos com dinâmicas inflacionárias muito distintas.

Isso será importante para a modelagem porque relações observadas em um regime econômico podem não se manter em outro.

### Dinâmica recente

Médias móveis e diferenças mensais ajudam a descrever o comportamento recente, mas ainda não representam automaticamente features válidas para forecasting.

### Estrutura temporal

O IPCA possui frequência mensal e servirá como referência para alinhar as demais variáveis macroeconômicas do projeto.

---

### Evolução do projeto

```
00.auditoria_dados
       |
       v
qualidade e integridade

01.selic
       |
       v
política monetária

02.ipca
       |
       v
inflação agregada

componentes do IPCA
       |
       v
decomposição da inflação

IPCA + SELIC
```

```
       |
       v
relações temporais

features
       |
       v
modelos estatísticos
       |
       v
machine learning
       |
       v
forecasting
```

O próximo passo é aprofundar a estrutura interna do IPCA antes de integrar inflação e política monetária em um mesmo problema de modelagem.