02.01. IPCA — Análise por Grupos

Sumário

Variação • Peso • Contribuição • Decomposição da Inflação . . . 2
Objetivos . . . 3
1. Estrutura hierárquica do IPCA . . . 3
2. O que representam os grupos? . . . 3
3. Três conceitos fundamentais . . . 4
4. Configuração do ambiente . . . 5
5. Importações . . . 5
6. Carregar dados do PostgreSQL . . . 6
7. Cobertura histórica . . . 7
8. Grupos disponíveis . . . 7
9. Quantidade de grupos ao longo do tempo . . . 8
10. Último mês disponível . . . 9
11. Soma dos pesos no último mês . . . 10
12. Estrutura atual dos pesos . . . 10
13. Evolução dos pesos . . . 11
PARTE II — VARIAÇÃO MENSAL DOS GRUPOS . . . 12
14. Janela recente de 10 anos . . . 12
15. Variação mensal por grupo . . . 13
16. Heatmap dos últimos 12 meses . . . 14
PARTE III — CONTRIBUIÇÃO DOS GRUPOS . . . 16
17. Calcular contribuição aproximada . . . 16
18. Inflação por grupo no último mês . . . 17
19. Contribuição por grupo no último mês . . . 18
20. Tabela do último mês . . . 20
21. Maiores pressões inflacionárias no último mês . . . 21
22. Maiores contribuições negativas no último mês . . . 21
PARTE IV — EVOLUÇÃO DAS CONTRIBUIÇÕES . . . 22
23. Contribuição dos grupos ao longo do tempo . . . 22
24. Matriz mensal das contribuições . . . 24
PARTE V — RELAÇÃO COM O IPCA GERAL . . . 25
25. Carregar IPCA geral . . . 25
26. Soma mensal das contribuições . . . 25
27. IPCA geral versus contribuição dos grupos . . . 26
28. Distribuição da diferença . . . 27
29. Evolução do erro . . . 27
30. Comparação no período recente . . . 28

PARTE VI — DINÂMICA ENTRE GRUPOS 29
31. Grupo de maior inflação por mês 29
32. Grupo de maior impacto por mês 30
33. Frequência como maior contribuição 31
PARTE VII — DATASET ANALÍTICO 32
34. Representação longa 32
35. Representação larga da variação mensal 33
36. Representação larga dos pesos 34
37. Representação larga das impacto 34
38. Implicações para futura modelagem 35
39. Conclusões 36

Variação ▪ Peso ▪ Contribuição ▪ Decomposição da Inflação

Este notebook inicia a decomposição do IPCA geral em seus grandes grupos de consumo.

Ele deve ser executado após:

```
00.auditoria_dados.ipynb
01.selic.ipynb
02.ipca.ipynb
```

O fluxo conceitual é:

```
IPCA geral
     |
     v
  grupos
     |
     v
subgrupos
     |
     v
   itens
     |
     v
 subitens
```

O notebook assume que:

- os pipelines já foram executados;
- a tabela `bcb.ipca_grupos` está atualizada;
- a auditoria dos dados foi concluída;
- os dados estão aptos para análise.

Este notebook NÃO executa pipelines e NÃO altera o banco de dados.

Objetivos

1. Entender o papel dos grupos na estrutura do IPCA.
2. Examinar a cobertura histórica dos grupos.
3. Analisar a evolução dos pesos.
4. Comparar a inflação entre grupos.
5. Calcular a contribuição aproximada de cada grupo.
6. Identificar quais grupos pressionam ou aliviam o IPCA agregado.
7. Relacionar os grupos ao IPCA geral.
8. Preparar uma representação analítica para etapas posteriores.

1. Estrutura hierárquica do IPCA

A estrutura utilizada pelo projeto é:

```
grupo      -> código de 1 dígito
subgrupo   -> código de 2 dígitos
item       -> código de 4 dígitos
subitem    -> código de 7 dígitos
```

Exemplos conceituais:

```
1       Alimentação e bebidas
11      Alimentação no domicílio
1101    Cereais, leguminosas e oleaginosas
1101002 Arroz
```

Neste notebook trabalharemos exclusivamente com o primeiro nível: `**grupos**`

2. O que representam os grupos?

Os grupos são grandes categorias de consumo utilizadas na estrutura do IPCA.

Exemplos incluem:

- Alimentação e bebidas;
- Habitação;
- Artigos de residência;
- Vestuário;
- Transportes;
- Saúde e cuidados pessoais;
- Despesas pessoais;
- Educação;
- Comunicação.

A análise por grupos permite começar a responder:

> Quais grandes componentes estão pressionando a inflação?

Isso representa um passo além do IPCA geral.

- IPCA geral → Quanto foi a inflação?
- IPCA por grupos → De onde veio a inflação?

3. Três conceitos fundamentais

Para interpretar corretamente os grupos precisamos distinguir:

```
índice
peso
contribuição
```

3.1 Variação mensal

A coluna:

```
indice
```

representa a variação mensal dos preços daquele grupo.

Exemplo:

```
Grupo A -> 1,50%
Grupo B -> 0,40%
```

Isso significa que os preços do Grupo A cresceram mais naquele mês.

Mas isso não significa necessariamente que o Grupo A tenha produzido maior impacto sobre o IPCA geral.

3.2 Peso

A coluna:

```
peso
```

representa a importância relativa do grupo na estrutura do índice.

Um grupo com peso maior exerce, para uma mesma variação de preços, impacto maior sobre o IPCA agregado.

3.3 Contribuição

Podemos construir uma aproximação da contribuição mensal:

$$Contribuio_{i,t} = ndice_{i,t} \times \frac{Peso_{i,t}}{100}$$

onde:

- i representa o grupo;
- t representa o mês.

Exemplo:

Grupo	Variação	Peso	Contribuição
A	5,00%	2%	0,10 p.p.
B	1,00%	25%	0,25 p.p.

Apesar de o Grupo A apresentar inflação maior, o Grupo B possui maior contribuição para o índice agregado.

Portanto:

- indice → quanto os preços variaram
- peso → quanto o grupo importa
- contribuição → quanto aproximadamente pressionou o IPCA

4. Configuração do ambiente

```
from pathlib import Path
import sys

PROJECT_ROOT = Path.cwd().resolve()

if PROJECT_ROOT.name == "notebooks":
    PROJECT_ROOT = PROJECT_ROOT.parent

if str(PROJECT_ROOT) not in sys.path:
    sys.path.insert(0, str(PROJECT_ROOT))

print("Project root:", PROJECT_ROOT)
```

```
Project root: /home/moacir/projects/ml/analytics/inflation
```

5. Importações

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from src.database.connection import engine

pd.set_option("display.max_columns", None)
pd.set_option("display.max_rows", 100)
pd.set_option("display.width", 160)
pd.set_option("display.float_format", "{:.4f}".format)
```

6. Carregar dados do PostgreSQL

A tabela utilizada é: `**bcb.ipca_grupos**`

O notebook apenas consome os dados já persistidos.

```
grupos = pd.read_sql(
    """
    SELECT
        date,
        categoria,
        categoria_nome,
        indice,
        peso
    FROM bcb.ipca_grupos
    ORDER BY date, categoria;
    """,
    engine,
)
```

6.1 Padronizar datas e ordenação

```
grupos["date"] = pd.to_datetime(grupos["date"])
grupos["categoria"] = (grupos["categoria"].astype(str))
grupos = (
    grupos
        .sort_values(
            ["date", "categoria"]
        )
        .reset_index(drop=True)
)

grupos.head(10)
```

	date	categoria	categoria_nome	indice	peso
0	2020-01-01	1	Alimentação e bebidas	0.3900	19.3483
1	2020-01-01	2	Habitação	0.5500	15.5945
2	2020-01-01	3	Artigos de residência	-0.0700	3.7529
3	2020-01-01	4	Vestuário	-0.4800	4.5770
4	2020-01-01	5	Transportes	0.3200	20.5979
5	2020-01-01	6	Saúde e cuidados pessoais	-0.3200	13.5334
6	2020-01-01	7	Despesas pessoais	0.3500	10.7330
7	2020-01-01	8	Educação	0.1600	6.1485
8	2020-01-01	9	Comunicação	0.1200	5.7146
9	2020-02-01	1	Alimentação e bebidas	0.1100	19.3816

7. Cobertura histórica

```
resumo_grupos = pd.DataFrame(
    [
        {
            "inicio": grupos["date"].min(),
            "fim": grupos["date"].max(),
            "observacoes": len(grupos),
            "categorias": grupos["categoria"].nunique(),
        }
    ]
)

resumo_grupos
```

	inicio	fim	observacoes	categorias
0	2020-01-01	2026-08-01	720	9

8. Grupos disponíveis

```
categorias = (
    grupos[
        [
            "categoria",
            "categoria_nome",
        ]
    ]
        .drop_duplicates()
        .sort_values("categoria")
        .reset_index(drop=True)
)
```

```
categorias
```

	categoria	categoria_nome
0	1	Alimentação e bebidas
1	2	Habitação
2	3	Artigos de residência
3	4	Vestuário
4	5	Transportes
5	6	Saúde e cuidados pessoais
6	7	Despesas pessoais
7	8	Educação
8	9	Comunicação

9. Quantidade de grupos ao longo do tempo

Mudanças metodológicas poderiam alterar a estrutura presente na base.

Por isso examinamos a quantidade de grupos disponível em cada mês.

```
quantidade_grupos = (
    grupos
    .groupby("date")["categoria"]
    .nunique()
    .rename("numero_grupos")
    .reset_index()
)

quantidade_grupos["numero_grupos"].describe()
```

```
count   80.0000
mean     9.0000
std      0.0000
min      9.0000
25%      9.0000
50%      9.0000
75%      9.0000
max      9.0000
Name: numero_grupos, dtype: float64
```

```
quantidade_grupos[
    quantidade_grupos["numero_grupos"]
    != quantidade_grupos["numero_grupos"].mode().iloc[0]
]
```

date	numero_grupos

PARTE I — ESTRUTURA ATUAL DO IPCA

10. Último mês disponível

```
ultimo_mes = grupos["date"].max()

grupos_ultimo = (
    grupos[
        grupos["date"] == ultimo_mes
    ]
    .copy()
)

print(
    "Último mês disponível:",
    ultimo_mes.strftime("%Y-%m"),
)

grupos_ultimo[
    [
        "categoria",
        "categoria_nome",
        "indice",
        "peso",
    ]
].sort_values("categoria")
```

```
Último mês disponível: 2026-08
```

	categoria	categoria_nome	indice	peso
711	1	Alimentação e bebidas	-0.3400	21.5115
712	2	Habitação	-1.8700	15.5030
713	3	Artigos de residência	0.6400	3.4510
714	4	Vestuário	0.1200	4.5963
715	5	Transportes	-0.8600	20.2696
716	6	Saúde e cuidados pessoais	0.2300	13.7648
717	7	Despesas pessoais	1.3000	10.2426
718	8	Educação	0.4700	6.1601
719	9	Comunicação	-0.0900	4.5011

11. Soma dos pesos no último mês

A soma dos pesos dos grupos deve representar aproximadamente a totalidade da estrutura agregada do índice.

Pequenas diferenças podem resultar de arredondamento.

```
soma_pesos_ultimo = (
    grupos_ultimo["peso"].sum()
)

print(
    f"Soma dos pesos em {ultimo_mes:%Y-%m}: "
    f"{soma_pesos_ultimo:.4f}"
)
```

```
Soma dos pesos em 2026-08: 100.0000
```

12. Estrutura atual dos pesos

Este gráfico mostra quais grupos possuem maior importância relativa na composição atual do IPCA.

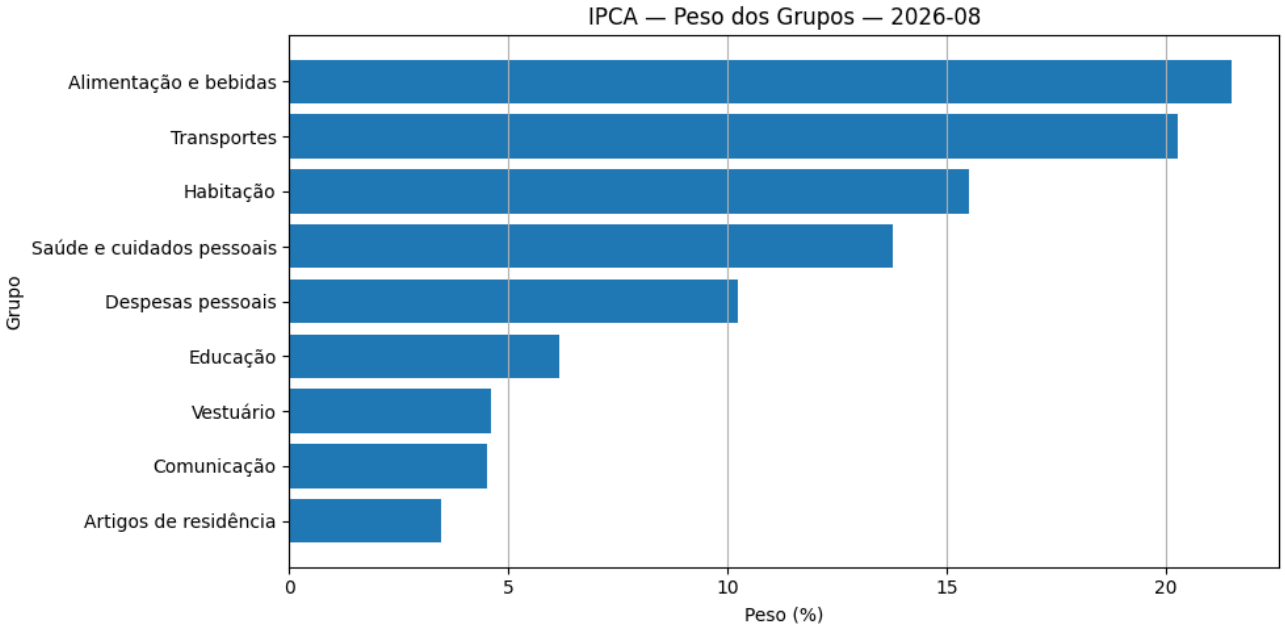
```
peso_atual = (
    grupos_ultimo
    .sort_values("peso")
)

plt.figure(figsize=(10, 5))

plt.barh(
    peso_atual["categoria_nome"],
    peso_atual["peso"],
)

plt.title(
    f"IPCA - Peso dos Grupos - {ultimo_mes:%Y-%m}"
)
plt.xlabel("Peso (%)")
plt.ylabel("Grupo")
plt.grid(True, axis="x")

plt.tight_layout()
plt.show()
```



13. Evolução dos pesos

O peso de um grupo pode mudar ao longo do tempo.

Portanto, uma média histórica do peso não representa necessariamente sua importância atual.

```
plt.figure(figsize=(11, 5))

for nome, grupo in grupos.groupby("categoria_nome"):
    grupo = grupo.sort_values("date")

    plt.plot(
        grupo["date"],
        grupo["peso"],
    )

    # Nome no último ponto da linha
    ultimo = grupo.iloc[-1]

    plt.annotate(
        nome,
        xy=(ultimo["date"], ultimo["peso"]),
        xytext=(6, 0),
        textcoords="offset points",
        va="center",
        fontsize=9,
    )

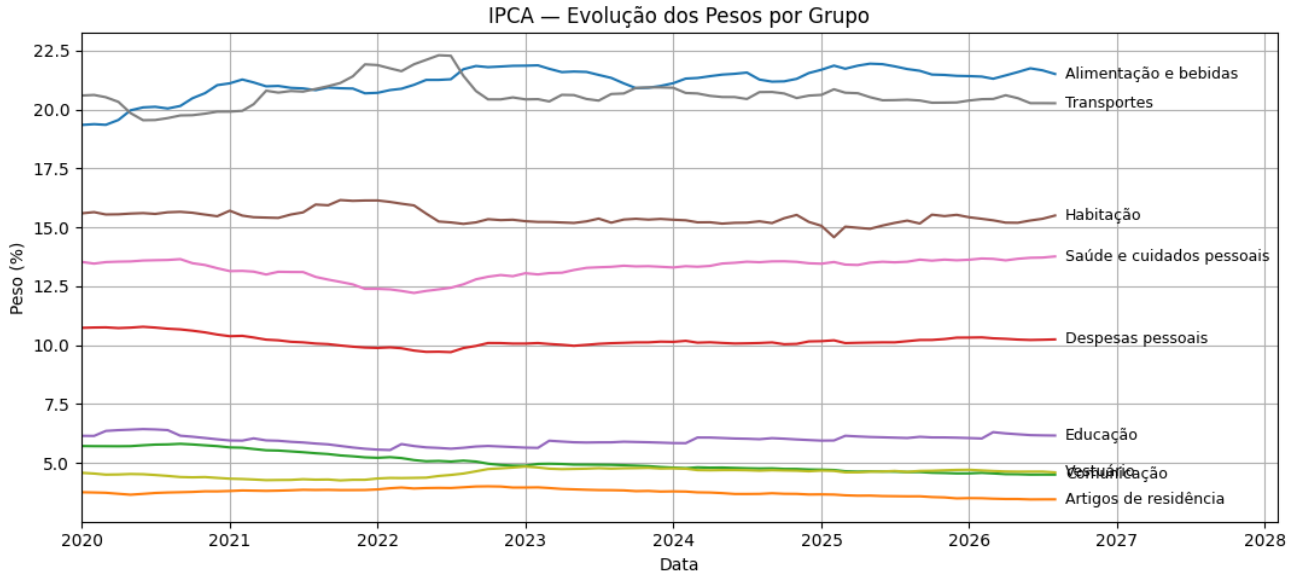
plt.title(
    "IPCA - Evolução dos Pesos por Grupo"
```

```
)
plt.xlabel("Data")
plt.ylabel("Peso (%)")
plt.grid(True)


# Espaço adicional à direita para os nomes
plt.xlim(
    grupos["date"].min(),
    grupos["date"].max() + pd.DateOffset(months=18),
)



plt.tight_layout()
plt.show()
```



PARTE II — VARIAÇÃO MENSAL DOS GRUPOS

14. Janela recente de 10 anos

O histórico completo pode combinar regimes econômicos bastante distintos.

Para facilitar a leitura da dinâmica contemporânea, criamos uma janela dos últimos 10 anos sem eliminar o histórico da base principal.

```
data_inicio_10a = (
    grupos["date"].max()
    - pd.DateOffset(years=10)
)

grupos_10a = grupos[
    grupos["date"] >= data_inicio_10a
].copy()
```

15. Variação mensal por grupo

```
nomes = sorted(
    grupos_10a["categoria_nome"].unique()
)

fig, axes = plt.subplots(
    3,
    3,
    figsize=(13, 8),
    sharex=True,
    sharey=True,
)

axes = axes.flatten()

for ax, nome in zip(axes, nomes):
    grupo = grupos_10a[
        grupos_10a["categoria_nome"] == nome
    ]

    ax.plot(
        grupo["date"],
        grupo["indice"],
        linewidth=1,
    )

    ax.axhline(
        0,
        color="black",
        linewidth=0.8,
    )

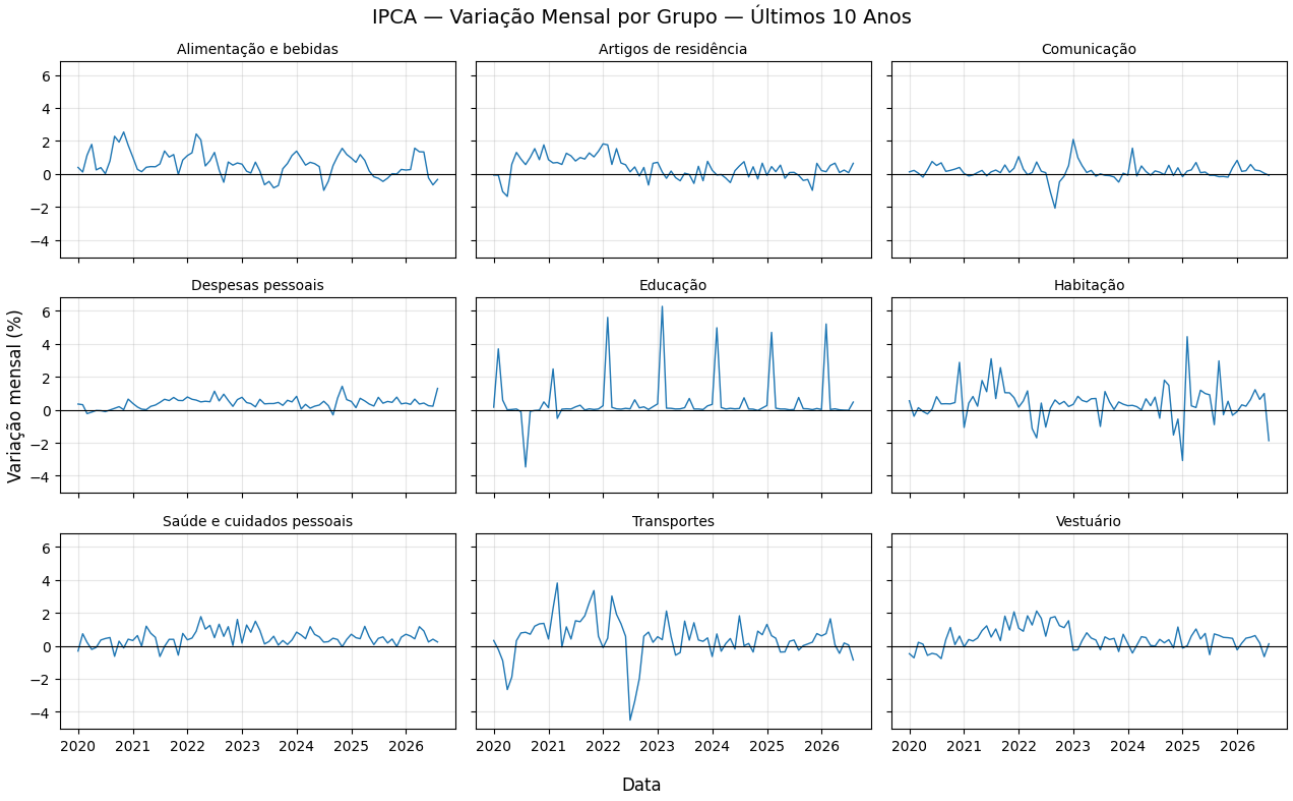
    ax.set_title(
        nome,
        fontsize=10,
    )
```

```
    ax.grid(
        True,
        alpha=0.3,
    )

fig.suptitle(
    "IPCA - Variação Mensal por Grupo - Últimos 10 Anos",
    fontsize=14,
)

fig.supxlabel("Data")
fig.supylabel("Variação mensal (%)")

plt.tight_layout()
plt.show()
```



16. Heatmap dos últimos 12 meses

O heatmap permite comparar simultaneamente:

- grupos;
- meses;
- intensidade da inflação;
- ocorrência de variações negativas.

```
ultimos_12_meses = (
    grupos["date"]
    .drop_duplicates()
    .sort_values()
    .tail(12)
)

grupos_12m = grupos[
    grupos["date"].isin(
        ultimos_12_meses
    )
].copy()

grupos_12m["periodo"] = (
    grupos_12m["date"]
    .dt.strftime("%Y-%m")
)

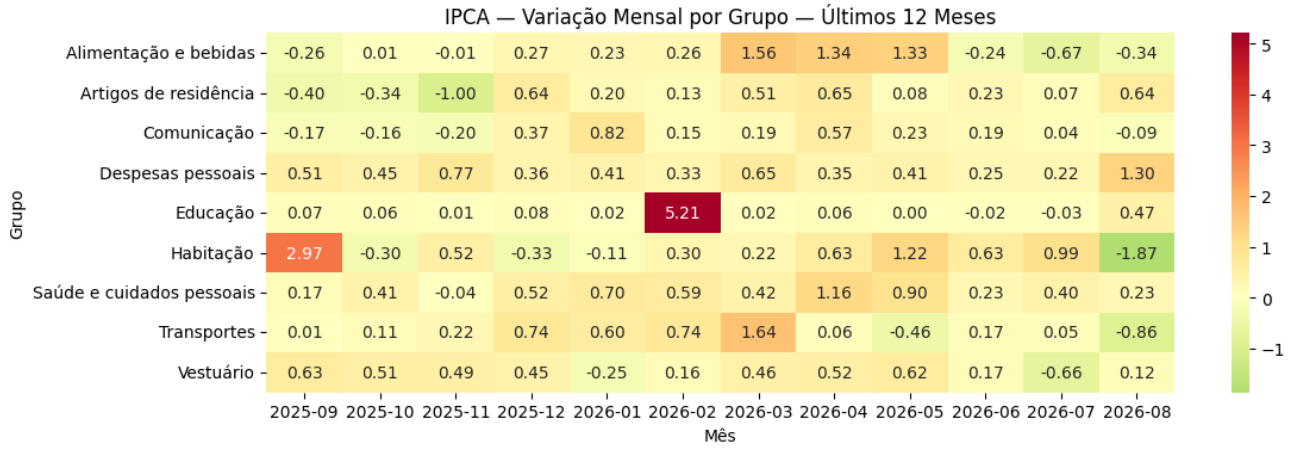
pivot_hm = grupos_12m.pivot(
    index="categoria_nome",
    columns="periodo",
    values="indice",
)
```

```
plt.figure(figsize=(12, 4))

sns.heatmap(
    pivot_hm,
    cmap="RdYlGn_r",
    center=0,
    annot=True,
    fmt=".2f",
)

plt.title(
    "IPCA - Variação Mensal por Grupo - Últimos 12 Meses"
)
plt.xlabel("Mês")
plt.ylabel("Grupo")

plt.tight_layout()
plt.show()
```



PARTE III — CONTRIBUIÇÃO DOS GRUPOS

17. Calcular contribuição aproximada

Utilizamos:

$$contribuio = indice \times \frac{peso}{100}$$

O resultado é expresso aproximadamente em pontos percentuais.

```
grupos["contribuicao"] = (
    grupos["indice"]
    * grupos["peso"]
    / 100
)

grupos["impacto"] = (
    grupos["contribuicao"].abs()
)

grupos[
    [
        "date",
        "categoria_nome",
        "indice",
        "peso",
        "contribuicao",
        "impacto",
    ]
].tail(18)
```

	date	categoria_nome	indice	peso	contribuicao	impacto
702	2026-07-01	Alimentação e bebidas	-0.6700	21.6675	-0.1452	0.1452
703	2026-07-01	Habitação	0.9900	15.3642	0.1521	0.1521
704	2026-07-01	Artigos de residência	0.0700	3.4504	0.0024	0.0024
705	2026-07-01	Vestuário	-0.6600	4.6289	-0.0306	0.0306
706	2026-07-01	Transportes	0.0500	20.2729	0.0101	0.0101
707	2026-07-01	Saúde e cuidados pessoais	0.4000	13.7181	0.0549	0.0549
708	2026-07-01	Despesas pessoais	0.2200	10.2281	0.0225	0.0225
709	2026-07-01	Educação	-0.0300	6.1673	-0.0019	0.0019
710	2026-07-01	Comunicação	0.0400	4.5026	0.0018	0.0018
711	2026-08-01	Alimentação e bebidas	-0.3400	21.5115	-0.0731	0.0731
712	2026-08-01	Habitação	-1.8700	15.5030	-0.2899	0.2899
713	2026-08-01	Artigos de residência	0.6400	3.4510	0.0221	0.0221
714	2026-08-01	Vestuário	0.1200	4.5963	0.0055	0.0055
715	2026-08-01	Transportes	-0.8600	20.2696	-0.1743	0.1743
716	2026-08-01	Saúde e cuidados pessoais	0.2300	13.7648	0.0317	0.0317
717	2026-08-01	Despesas pessoais	1.3000	10.2426	0.1332	0.1332
718	2026-08-01	Educação	0.4700	6.1601	0.0290	0.0290
719	2026-08-01	Comunicação	-0.0900	4.5011	-0.0041	0.0041

17.1 Atualizar os recortes temporais

Como `contribuicao` foi criada após os recortes anteriores, atualizamos as visões utilizadas nas próximas análises.

```
grupos_ultimo = grupos[
    grupos["date"] == ultimo_mes
].copy()

grupos_10a = grupos[
    grupos["date"] >= data_inicio_10a
].copy()
```

18. Inflação por grupo no último mês

Esta visão responde:

> Quais grupos tiveram maior e menor variação de preços?

```
variacao_ultimo = (
    grupos_ultimo
    .sort_values("indice")
)

plt.figure(figsize=(10, 6))

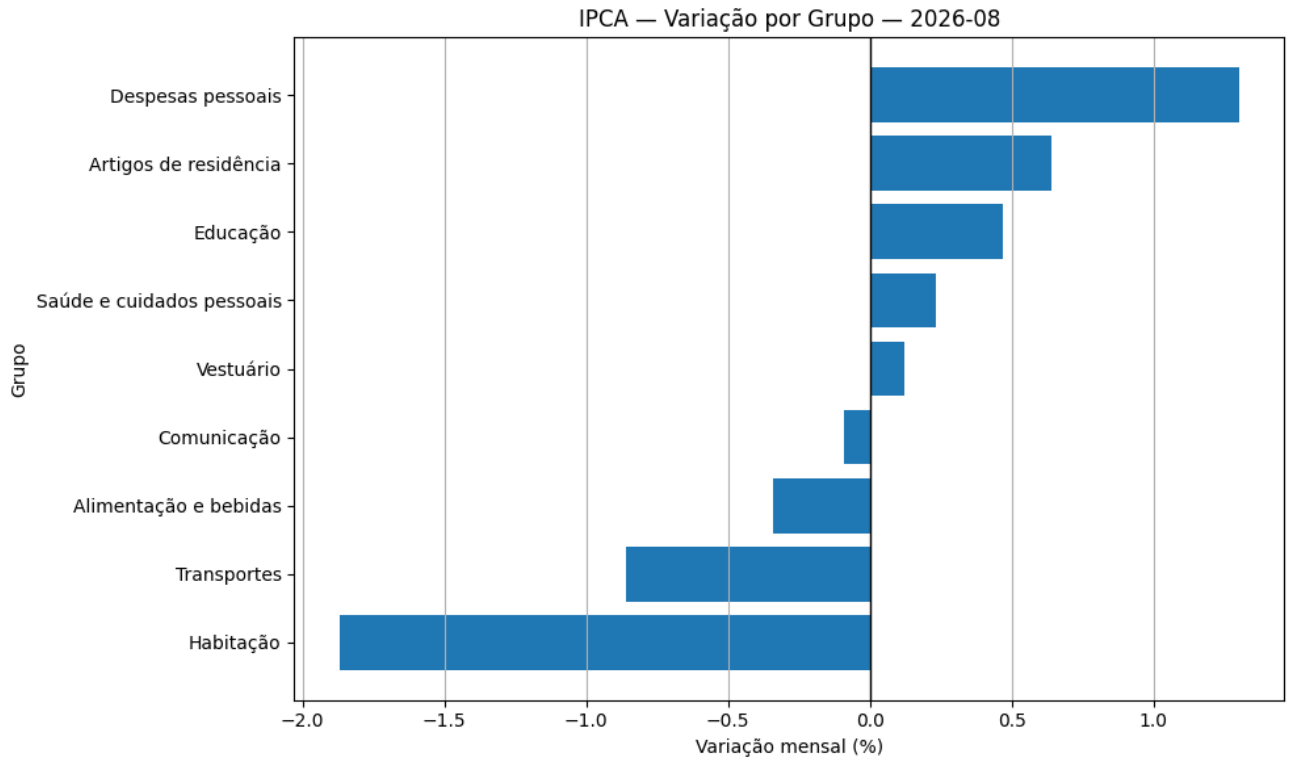
plt.barh(
```

```
    variacao_ultimo["categoria_nome"],
    variacao_ultimo["indice"],
)

plt.axvline(
    0,
    color="black",
    linewidth=1,
)

plt.title(
    f"IPCA - Variação por Grupo - {ultimo_mes:%Y-%m}"
)
plt.xlabel("Variação mensal (%)")
plt.ylabel("Grupo")
plt.grid(True, axis="x")

plt.tight_layout()
plt.show()
```



19. Contribuição por grupo no último mês

Esta visão responde a uma pergunta diferente:

> Quais grupos mais pressionaram ou aliviaram o IPCA agregado?

```
contribuicao_ultimo = (
    grupos_ultimo
    .sort_values("contribuicao")
)

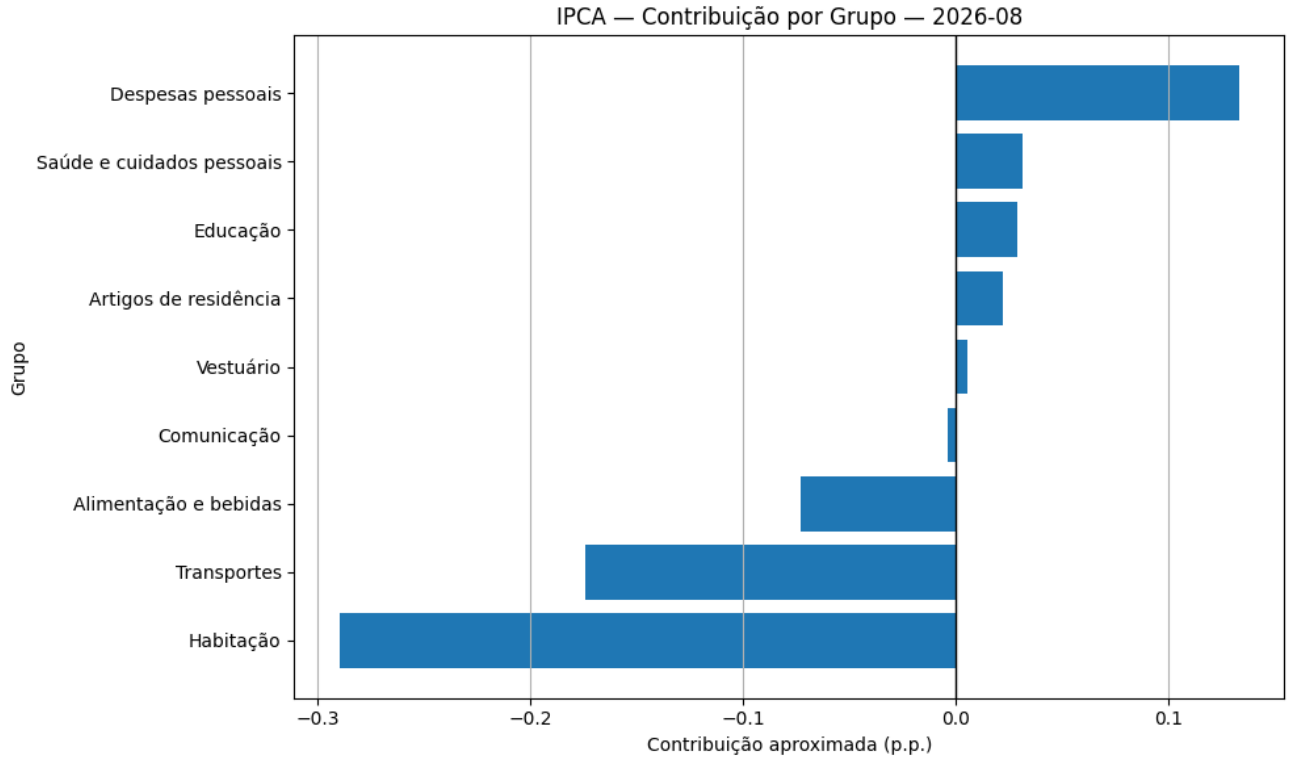
plt.figure(figsize=(10, 6))

plt.barh(
    contribuicao_ultimo["categoria_nome"],
    contribuicao_ultimo["contribuicao"],
)

plt.axvline(
    0,
    color="black",
    linewidth=1,
)

plt.title(
    f"IPCA - Contribuição por Grupo - {ultimo_mes:%Y-%m}"
)
plt.xlabel("Contribuição aproximada (p.p.)")
plt.ylabel("Grupo")
plt.grid(True, axis="x")

plt.tight_layout()
plt.show()
```



20. Tabela do último mês

A comparação conjunta entre:

```
indice
peso
contribuição
impacto
```

é uma das formas mais importantes de interpretar os grupos. * tabela organizada por impacto no mês

```
resumo_ultimo_mes = (
    grupos_ultimo[
        [
            "categoria",
            "categoria_nome",
            "indice",
            "peso",
            "contribuicao",
            "impacto",
        ]
    ]
    .sort_values(
        "impacto",
        ascending=False,
```

```
    )
    .reset_index(drop=True)
)

resumo_ultimo_mes
```

	categoria	categoria_nome	indice	peso	contribuicao	impacto
0	2	Habitação	-1.8700	15.5030	-0.2899	0.2899
1	5	Transportes	-0.8600	20.2696	-0.1743	0.1743
2	7	Despesas pessoais	1.3000	10.2426	0.1332	0.1332
3	1	Alimentação e bebidas	-0.3400	21.5115	-0.0731	0.0731
4	6	Saúde e cuidados pessoais	0.2300	13.7648	0.0317	0.0317
5	8	Educação	0.4700	6.1601	0.0290	0.0290
6	3	Artigos de residência	0.6400	3.4510	0.0221	0.0221
7	4	Vestuário	0.1200	4.5963	0.0055	0.0055
8	9	Comunicação	-0.0900	4.5011	-0.0041	0.0041

21. Maiores pressões inflacionárias no último mês

```
resumo_ultimo_mes.nlargest(
    5,
    "contribuicao",
)
```

	categoria	categoria_nome	indice	peso	contribuicao	impacto
2	7	Despesas pessoais	1.3000	10.2426	0.1332	0.1332
4	6	Saúde e cuidados pessoais	0.2300	13.7648	0.0317	0.0317
5	8	Educação	0.4700	6.1601	0.0290	0.0290
6	3	Artigos de residência	0.6400	3.4510	0.0221	0.0221
7	4	Vestuário	0.1200	4.5963	0.0055	0.0055

22. Maiores contribuições negativas no último mês

```
resumo_ultimo_mes.nsmallest(
    5,
    "contribuicao",
)
```

	categoria	categoria_nome	indice	peso	contribuicao	impacto
0	2	Habitação	-1.8700	15.5030	-0.2899	0.2899
1	5	Transportes	-0.8600	20.2696	-0.1743	0.1743

	categoria	categoria_nome	indice	peso	contribuicao	impacto
3	1	Alimentação e bebidas	-0.3400	21.5115	-0.0731	0.0731
8	9	Comunicação	-0.0900	4.5011	-0.0041	0.0041
7	4	Vestuário	0.1200	4.5963	0.0055	0.0055

PARTE IV — EVOLUÇÃO DAS CONTRIBUIÇÕES

23. Contribuição dos grupos ao longo do tempo

A contribuição combina:

```
       variação do grupo
              ×
       peso do grupo
              =
   contribuição para o IPCA
```

Como as contribuições possuem sinal:

- valores positivos pressionam o IPCA para cima;
- valores negativos reduzem o IPCA no mês.

O gráfico empilhado permite observar simultaneamente:

- a direção da contribuição;
- a magnitude;
- quais grupos dominaram cada mês;
- como a composição da inflação mudou ao longo do tempo.

Para preservar a legibilidade, utilizamos os últimos 36 meses.

```
data_inicio_36m = (
    grupos["date"].max()
    - pd.DateOffset(months=35)
)

contrib_36m = (
    grupos[
        grupos["date"] >= data_inicio_36m
    ]
    .pivot(
        index="date",
        columns="categoria_nome",
        values="contribuicao",
    )
```

```
    .fillna(0)
    .sort_index()
)

# Para o gráfico de barras, usar o mês como categoria
contrib_36m.index = (
    contrib_36m.index.strftime("%Y-%m")
)
```

```
ax = contrib_36m.plot(
    kind="bar",
    stacked=True,
    figsize=(16, 7),
    width=0.85,
)

ax.axhline(
    0,
    color="black",
    linewidth=1,
)

ax.set_title(
    "IPCA - Contribuição Mensal por Grupo - Últimos 36 Meses"
)

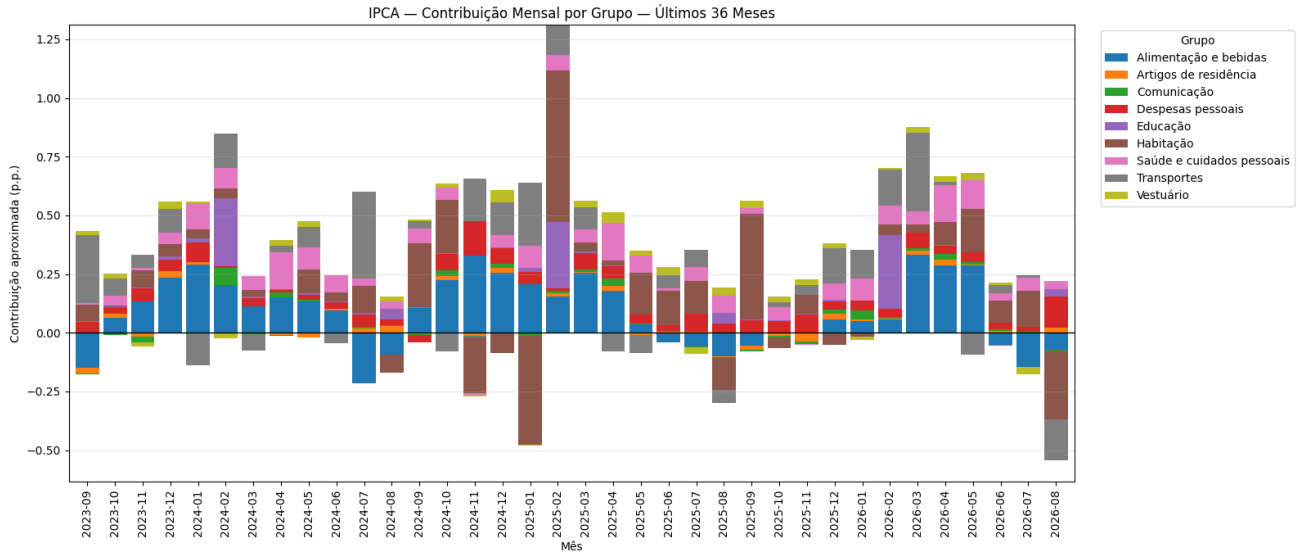
ax.set_xlabel("Mês")
ax.set_ylabel("Contribuição aproximada (p.p.)")

ax.legend(
    title="Grupo",
    bbox_to_anchor=(1.02, 1),
    loc="upper left",
)

plt.xticks(
    rotation=90
)

plt.grid(
    True,
    axis="y",
    alpha=0.3,
)

plt.tight_layout()
plt.show()
```



24. Matriz mensal das contribuições

Transformamos os grupos em colunas.

Essa representação será particularmente útil quando chegarmos à construção de features.

```
contrib_pivot = (
    grupos
    .pivot(
        index="date",
        columns="categoria_nome",
        values="contribuicao",
    )
    .sort_index()
)

contrib_pivot.tail(12)
```

categoria_nome date	Alimentação e bebidas	Artigos de residência	Comunicação	Despesas pessoais	Educação
2025-09-01	-0.0563	-0.0143	-0.0078	0.0521	0.0043
2025-10-01	0.0021	-0.0121	-0.0073	0.0460	0.0036
2025-11-01	-0.0021	-0.0353	-0.0091	0.0790	0.0006
2025-12-01	0.0579	0.0223	0.0168	0.0371	0.0049
2026-01-01	0.0493	0.0070	0.0373	0.0423	0.0012
2026-02-01	0.0556	0.0045	0.0069	0.0341	0.3144
2026-03-01	0.3324	0.0177	0.0086	0.0669	0.0013
2026-04-01	0.2875	0.0225	0.0258	0.0359	0.0038
2026-05-01	0.2872	0.0028	0.0104	0.0420	0.0000
2026-06-01	-0.0522	0.0079	0.0086	0.0255	-0.0012
2026-07-01	-0.1452	0.0024	0.0018	0.0225	-0.0019

categoria_nome date	Alimentação e bebidas	Artigos de residência	Comunicação	Despesas pessoais	Educação
2026-08-01	-0.0731	0.0221	-0.0041	0.1332	0.0290

PARTE V — RELAÇÃO COM O IPCA GERAL

25. Carregar IPCA geral

Neste ponto faz sentido trazer o agregado para comparar sua evolução com a soma aproximada das contribuições dos grupos.

Isso NÃO substitui a auditoria feita no notebook 00.

Aqui a comparação possui objetivo analítico.

```
ipca_geral = pd.read_sql(
    """
    SELECT
        date,
        indice AS ipca_geral
    FROM bcb.ipca_geral
    ORDER BY date;
    """,
    engine,
)

ipca_geral["date"] = pd.to_datetime(
    ipca_geral["date"]
)

ipca_geral = (
    ipca_geral
    .sort_values("date")
    .reset_index(drop=True)
)
```

26. Soma mensal das contribuições

```
contrib_total = (
    grupos
    .groupby(
        "date",
        as_index=False,
    )["contribuicao"]
```

```
    .sum()
    .rename(
        columns={
            "contribuicao":
            "contribuicao_grupos"
        }
    )
)

contrib_total.tail(12)
```

	date	contribuicao_grupos
68	2025-09-01	0.4829
69	2025-10-01	0.0876
70	2025-11-01	0.1756
71	2025-12-01	0.3299
72	2026-01-01	0.3261
73	2026-02-01	0.7011
74	2026-03-01	0.8748
75	2026-04-01	0.6654
76	2026-05-01	0.5852
77	2026-06-01	0.1588
78	2026-07-01	0.0663
79	2026-08-01	-0.3200

27. IPCA geral versus contribuição dos grupos

```
comparacao = (
    ipca_geral
    .merge(
        contrib_total,
        on="date",
        how="inner",
        validate="one_to_one",
    )
)

comparacao["erro"] = (
    comparacao["contribuicao_grupos"]
    - comparacao["ipca_geral"]
)

comparacao["erro_abs"] = (
    comparacao["erro"].abs()
)
```

```
comparacao.tail(12)
```

	date	ipca_geral	contribuicao_grupos	erro	erro_abs
68	2025-09-01	0.4800	0.4829	0.0029	0.0029
69	2025-10-01	0.0900	0.0876	-0.0024	0.0024
70	2025-11-01	0.1800	0.1756	-0.0044	0.0044
71	2025-12-01	0.3300	0.3299	-0.0001	0.0001
72	2026-01-01	0.3300	0.3261	-0.0039	0.0039
73	2026-02-01	0.7000	0.7011	0.0011	0.0011
74	2026-03-01	0.8800	0.8748	-0.0052	0.0052
75	2026-04-01	0.6700	0.6654	-0.0046	0.0046
76	2026-05-01	0.5800	0.5852	0.0052	0.0052
77	2026-06-01	0.1600	0.1588	-0.0012	0.0012
78	2026-07-01	0.0700	0.0663	-0.0037	0.0037
79	2026-08-01	-0.3200	-0.3200	-0.0000	0.0000

28. Distribuição da diferença

Pequenas diferenças podem decorrer de arredondamentos e características metodológicas dos valores disponibilizados.

O objetivo aqui é observar a magnitude dessa diferença.

```
comparacao["erro"].describe()
```

```
count   80.0000
mean    -0.0004
std      0.0033
min     -0.0065
25%     -0.0035
50%     -0.0008
75%      0.0024
max      0.0066
Name: erro, dtype: float64
```

29. Evolução do erro

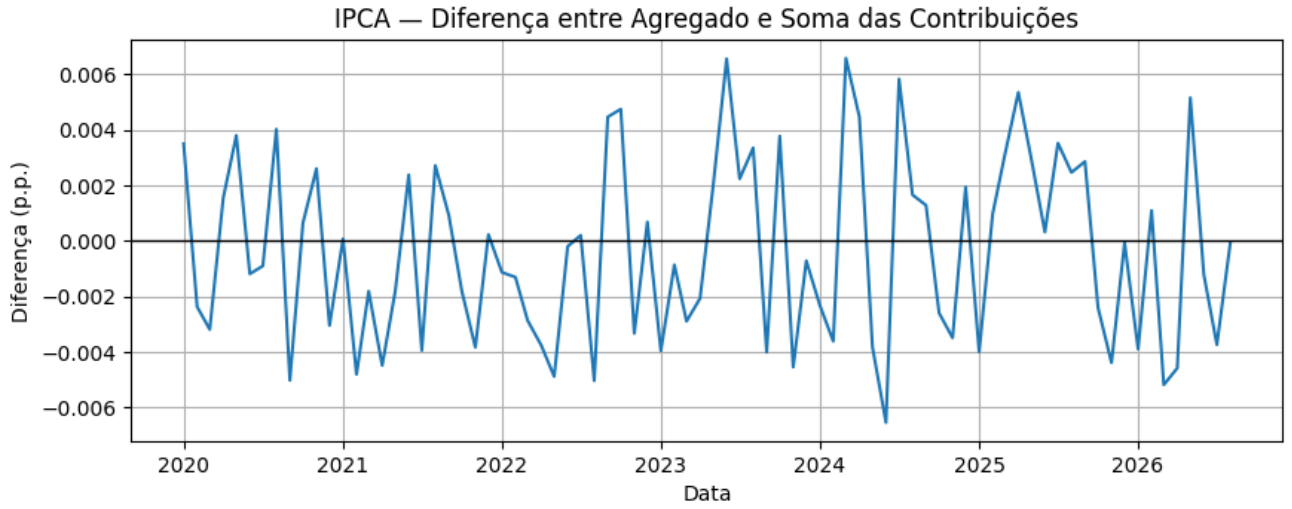
```
plt.figure(figsize=(10, 3.5))

plt.plot(
    comparacao["date"],
    comparacao["erro"],
)
```

```
plt.axhline(
    0,
    color="black",
    linewidth=1,
)

plt.title(
    "IPCA - Diferença entre Agregado e Soma das Contribuições"
)
plt.xlabel("Data")
plt.ylabel("Diferença (p.p.)")
plt.grid(True)

plt.show()
```



30. Comparação no período recente

```
comparacao_10a = comparacao[
    comparacao["date"] >= data_inicio_10a
].copy()

plt.figure(figsize=(10, 4))

plt.plot(
    comparacao_10a["date"],
    comparacao_10a["ipca_geral"],
    label="IPCA geral",
    linewidth=2,
)

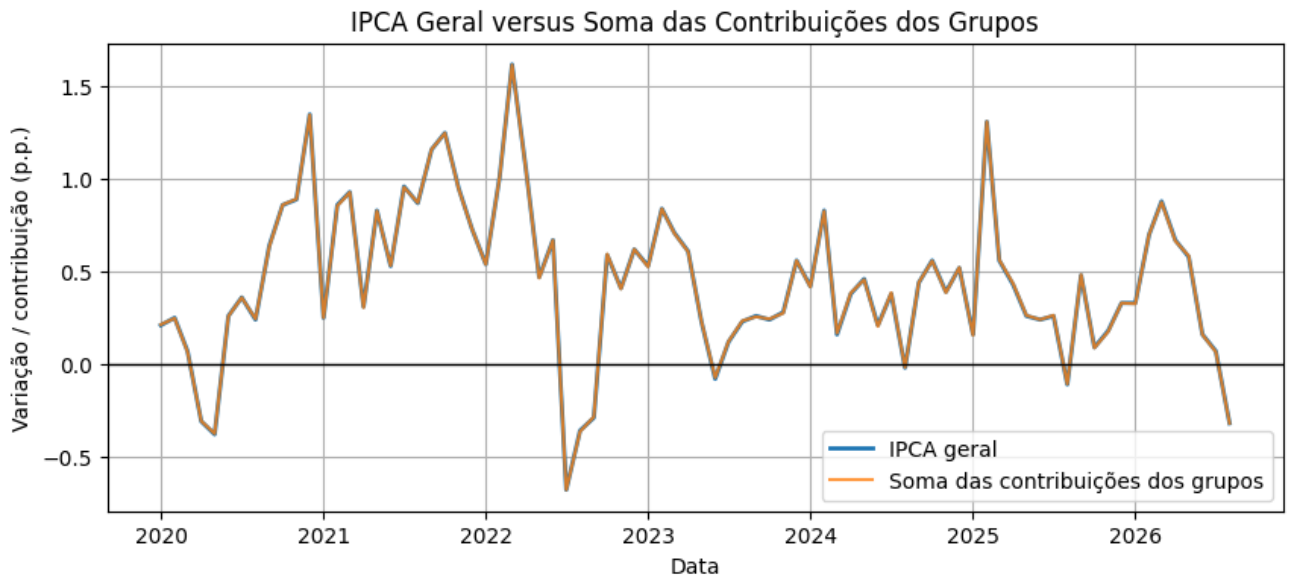
plt.plot(
```

```
    comparacao_10a["date"],
    comparacao_10a["contribuicao_grupos"],
    label="Soma das contribuições dos grupos",
    alpha=0.8,
)

plt.axhline(
    0,
    color="black",
    linewidth=1,
)

plt.title(
    "IPCA Geral versus Soma das Contribuições dos Grupos"
)
plt.xlabel("Data")
plt.ylabel("Variação / contribuição (p.p.)")
plt.grid(True)
plt.legend()

plt.show()
```



PARTE VI — DINÂMICA ENTRE GRUPOS

31. Grupo de maior inflação por mês

Podemos identificar qual grupo apresentou a maior variação mensal em cada período.

```
idx_maior_inflacao = (
    grupos
    .groupby("date")["indice"]
    .idxmax()
)

maior_inflacao_mes = (
    grupos.loc[
        idx_maior_inflacao,
        [
            "date",
            "categoria_nome",
            "indice",
            "peso",
            "contribuicao",
        ],
    ]
    .sort_values("date")
    .reset_index(drop=True)
)

maior_inflacao_mes.tail(12)
```

	date	categoria_nome	indice	peso	contribuicao
68	2025-09-01	Habitação	2.9700	15.1636	0.4504
69	2025-10-01	Vestuário	0.5100	4.6654	0.0238
70	2025-11-01	Despesas pessoais	0.7700	10.2567	0.0790
71	2025-12-01	Transportes	0.7400	20.3033	0.1502
72	2026-01-01	Comunicação	0.8200	4.5542	0.0373
73	2026-02-01	Educação	5.2100	6.0348	0.3144
74	2026-03-01	Transportes	1.6400	20.4516	0.3354
75	2026-04-01	Alimentação e bebidas	1.3400	21.4524	0.2875
76	2026-05-01	Alimentação e bebidas	1.3300	21.5939	0.2872
77	2026-06-01	Habitação	0.6300	15.2915	0.0963
78	2026-07-01	Habitação	0.9900	15.3642	0.1521
79	2026-08-01	Despesas pessoais	1.3000	10.2426	0.1332

32. Grupo de maior impacto por mês

O grupo que apresenta maior inflação não é necessariamente o grupo de maior impacto.

```
idx_maior_contrib = (
    grupos
    .groupby("date")["impacto"]
    .idxmax()
)
```

```
maior_contrib_mes = (
    grupos.loc[
        idx_maior_contrib,
        [
            "date",
            "categoria_nome",
            "indice",
            "peso",
            "impacto",
        ],
    ]
    .sort_values("date")
    .reset_index(drop=True)
)

maior_contrib_mes.tail(12)
```

	date	categoria_nome	indice	peso	impacto
68	2025-09-01	Habitação	2.9700	15.1636	0.4504
69	2025-10-01	Saúde e cuidados pessoais	0.4100	13.5865	0.0557
70	2025-11-01	Habitação	0.5200	15.4783	0.0805
71	2025-12-01	Transportes	0.7400	20.3033	0.1502
72	2026-01-01	Transportes	0.6000	20.3868	0.1223
73	2026-02-01	Educação	5.2100	6.0348	0.3144
74	2026-03-01	Transportes	1.6400	20.4516	0.3354
75	2026-04-01	Alimentação e bebidas	1.3400	21.4524	0.2875
76	2026-05-01	Alimentação e bebidas	1.3300	21.5939	0.2872
77	2026-06-01	Habitação	0.6300	15.2915	0.0963
78	2026-07-01	Habitação	0.9900	15.3642	0.1521
79	2026-08-01	Habitação	-1.8700	15.5030	0.2899

33. Frequência como maior contribuição

Esta tabela conta quantas vezes cada grupo foi a maior contribuição inflacionária do mês no histórico disponível.

```
frequencia_maior_contrib = (
    maior_contrib_mes["categoria_nome"]
    .value_counts()
    .rename("meses")
    .to_frame()
)

frequencia_maior_contrib
```

categoria_nome	meses
Alimentação e bebidas	27
Transportes	22
Habitação	19
Educação	6
Saúde e cuidados pessoais	6

PARTE VII — DATASET ANALÍTICO

34. Representação longa

O formato original é adequado para análises por categoria:

- date
- categoria
- categoria_nome
- indice
- peso
- contribuicao

```
grupos_analitico = grupos[
    [
        "date",
        "categoria",
        "categoria_nome",
        "indice",
        "peso",
        "contribuicao",
    ]
].copy()

grupos_analitico.tail(18)
```

	date	categoria	categoria_nome	indice	peso	contribuicao
702	2026-07-01	1	Alimentação e bebidas	-0.6700	21.6675	-0.1452
703	2026-07-01	2	Habitação	0.9900	15.3642	0.1521
704	2026-07-01	3	Artigos de residência	0.0700	3.4504	0.0024
705	2026-07-01	4	Vestuário	-0.6600	4.6289	-0.0306
706	2026-07-01	5	Transportes	0.0500	20.2729	0.0101
707	2026-07-01	6	Saúde e cuidados pessoais	0.4000	13.7181	0.0549
708	2026-07-01	7	Despesas pessoais	0.2200	10.2281	0.0225
709	2026-07-01	8	Educação	-0.0300	6.1673	-0.0019
710	2026-07-01	9	Comunicação	0.0400	4.5026	0.0018

	date	categoria	categoria_nome	indice	peso	contribuicao
711	2026-08-01	1	Alimentação e bebidas	-0.3400	21.5115	-0.0731
712	2026-08-01	2	Habitação	-1.8700	15.5030	-0.2899
713	2026-08-01	3	Artigos de residência	0.6400	3.4510	0.0221
714	2026-08-01	4	Vestuário	0.1200	4.5963	0.0055
715	2026-08-01	5	Transportes	-0.8600	20.2696	-0.1743
716	2026-08-01	6	Saúde e cuidados pessoais	0.2300	13.7648	0.0317
717	2026-08-01	7	Despesas pessoais	1.3000	10.2426	0.1332
718	2026-08-01	8	Educação	0.4700	6.1601	0.0290
719	2026-08-01	9	Comunicação	-0.0900	4.5011	-0.0041

35. Representação larga da variação mensal

Para futura modelagem, uma possibilidade é transformar cada grupo em uma coluna.

```
indice_pivot = (
    grupos
    .pivot(
        index="date",
        columns="categoria_nome",
        values="indice",
    )
    .sort_index()
)

indice_pivot.tail(12)
```

categoria_nome date	Alimentação e bebidas	Artigos de residência	Comunicação	Despesas pessoais	Educação
2025-09-01	-0.2600	-0.4000	-0.1700	0.5100	0.0700
2025-10-01	0.0100	-0.3400	-0.1600	0.4500	0.0600
2025-11-01	-0.0100	-1.0000	-0.2000	0.7700	0.0100
2025-12-01	0.2700	0.6400	0.3700	0.3600	0.0800
2026-01-01	0.2300	0.2000	0.8200	0.4100	0.0200
2026-02-01	0.2600	0.1300	0.1500	0.3300	5.2100
2026-03-01	1.5600	0.5100	0.1900	0.6500	0.0200
2026-04-01	1.3400	0.6500	0.5700	0.3500	0.0600
2026-05-01	1.3300	0.0800	0.2300	0.4100	0.0000
2026-06-01	-0.2400	0.2300	0.1900	0.2500	-0.0200
2026-07-01	-0.6700	0.0700	0.0400	0.2200	-0.0300
2026-08-01	-0.3400	0.6400	-0.0900	1.3000	0.4700

36. Representação larga dos pesos

```
peso_pivot = (
    grupos
    .pivot(
        index="date",
        columns="categoria_nome",
        values="peso",
    )
    .sort_index()
)

peso_pivot.tail(12)
```

categoria_nome date	Alimentação e bebidas	Artigos de residência	Comunicação	Despesas pessoais	Educação
2025-09-01	21.6477	3.5799	4.6107	10.2173	6.1065
2025-10-01	21.4882	3.5485	4.5808	10.2196	6.0810
2025-11-01	21.4722	3.5331	4.5697	10.2567	6.0795
2025-12-01	21.4332	3.4919	4.5529	10.3169	6.0689
2026-01-01	21.4221	3.5028	4.5542	10.3196	6.0534
2026-02-01	21.4014	3.4983	4.5768	10.3280	6.0348
2026-03-01	21.3095	3.4789	4.5518	10.2891	6.3035
2026-04-01	21.4524	3.4660	4.5210	10.2667	6.2508
2026-05-01	21.5939	3.4654	4.5171	10.2357	6.2144
2026-06-01	21.7530	3.4480	4.5015	10.2184	6.1780
2026-07-01	21.6675	3.4504	4.5026	10.2281	6.1673
2026-08-01	21.5115	3.4510	4.5011	10.2426	6.1601

37. Representação larga das impacto

```
contrib_pivot.tail(12)
```

categoria_nome date	Alimentação e bebidas	Artigos de residência	Comunicação	Despesas pessoais	Educação
2025-09-01	-0.0563	-0.0143	-0.0078	0.0521	0.0043
2025-10-01	0.0021	-0.0121	-0.0073	0.0460	0.0036
2025-11-01	-0.0021	-0.0353	-0.0091	0.0790	0.0006
2025-12-01	0.0579	0.0223	0.0168	0.0371	0.0049
2026-01-01	0.0493	0.0070	0.0373	0.0423	0.0012
2026-02-01	0.0556	0.0045	0.0069	0.0341	0.3144
2026-03-01	0.3324	0.0177	0.0086	0.0669	0.0013
2026-04-01	0.2875	0.0225	0.0258	0.0359	0.0038

categoria_nome date	Alimentação e bebidas	Artigos de residência	Comunicação	Despesas pessoais	Educação
2026-05-01	0.2872	0.0028	0.0104	0.0420	0.0000
2026-06-01	-0.0522	0.0079	0.0086	0.0255	-0.0012
2026-07-01	-0.1452	0.0024	0.0018	0.0225	-0.0019
2026-08-01	-0.0731	0.0221	-0.0041	0.1332	0.0290

38. Implicações para futura modelagem

Os grupos criam novas possibilidades de features.

Um vetor de informações em determinado mês poderia conter: $X_t = [Alimentao_t, Habitao_t, Transportes_t, Sade_t, ...]$

ou suas contribuições: $X_t = [ContribAlimentao_t, ContribHabitao_t, ContribTransportes_t, ...]$

Posteriormente também poderemos trabalhar com defasagens: $X_t = [Grupo1_{t-1}, Grupo1_{t-2}, Grupo2_{t-1}, ...]$

Contudo, ainda NÃO estamos criando o dataset final de machine learning.

38.1 Cuidados futuros

A inclusão dos grupos em modelos exigirá atenção a:

- **Multicolinearidade**
  Os grupos participam da construção do próprio IPCA agregado.
  Portanto, várias features podem carregar informações correlacionadas.
- Leakage temporal
  Para prever o IPCA de um mês futuro, só poderemos utilizar informações disponíveis no momento da previsão.
- Disponibilidade da informação
  Um valor publicado juntamente com o target não pode ser usado como feature para prever aquele mesmo target em uma aplicação real de forecasting.
- Mudanças estruturais
  Pesos e relações entre categorias podem mudar ao longo do tempo.
- Dimensionalidade
  A quantidade de variáveis crescerá significativamente quando avançarmos para:
  - subgrupos
  - itens
  - subitens

Esse ponto será importante para métodos de regularização e seleção de features.

---

39. Conclusões

Este notebook iniciou a decomposição da inflação agregada.

Variação

A variação mensal responde: > Quais grupos tiveram os maiores movimentos de preços?

Peso

O peso responde: > Qual é a importância relativa de cada grupo na estrutura do IPCA?

Contribuição

A contribuição combina as duas dimensões: $contribuio = variao \times peso$

e responde: > Quais grupos efetivamente exerceram maior pressão sobre o IPCA?

Progressão analítica

Neste ponto temos:

```
02.ipca
    |
    v
inflação agregada
    |
    v
02.01.grupos
    |
    v
decomposição em grandes componentes
```

O próximo nível hierárquico permitirá decompor cada grupo:

```
grupo
  |
  v
subgrupo
  |
  v
item
  |
  v
subitem
```

Essa progressão permitirá distinguir:

```
quanto foi a inflação
         |
         v
quais grupos explicaram
         |
         v
quais componentes internos explicaram os grupos
```

Posteriormente essa estrutura será integrada às variáveis macroeconômicas e à SELIC para construção dos datasets de modelagem.