02.04. IPCA — Análise por Subitens

Sumário

Parte 0 — Granularidade • Impacto • Difusão • Concentração • Hierarquia 2
Objetivos 3
1. Hierarquia do IPCA 3
2. O que representa um subitem? 4
3. Estrutura matemática 4
4. Configuração do ambiente 5
5. Importações 5
6. Carregar subitens do PostgreSQL 5
7. Carregar referências hierárquicas 7
8. Cobertura histórica 10
9. Catálogo hierárquico 11
10. Quantidade de subitens por item 12
PARTE I — ÚLTIMO MÊS 13
11. Último mês disponível 13
12. Subitens com maior peso 14
13. Maiores variações positivas 15
14. Maiores variações negativas 16
15. Principais pressões 17
16. Gráfico das principais pressões 18
17. Direção das principais pressões 20
PARTE II — DISTRIBUIÇÃO DOS MOVIMENTOS 21
18. Distribuição das variações 21
19. Estatísticas da distribuição 22
20. Dispersão 22
21. Valores extremos 23
PARTE III — DIFUSÃO 25
22. Definição 25
23. Calcular difusão 26
24. Difusão no último mês 27
25. Evolução recente da difusão 27
26. Interpretação 28
PARTE IV — CONCENTRAÇÃO DAS PRESSÕES 29
27. Impacto total 29
28. Concentração nos maiores impactos 30
29. Evolução da concentração 31
30. Difusão versus concentração 33

PARTE V — ANÁLISE DENTRO DE UM ITEM . . . 33
31. Selecionar item . . . 33
32. Subitens do item no último mês . . . 34
33. Pressões dentro do item . . . 35
34. Direção das pressões dentro do item . . . 37
PARTE VI — CONSISTÊNCIA COM OS ITENS . . . 38
35. Relação hierárquica . . . 38
36. Carregar itens para comparação . . . 39
37. Somar contribuições dos subitens . . . 39
38. Comparar item e soma dos subitens . . . 40
39. Erro de reconstrução . . . 41
40. Maiores erros de reconstrução . . . 42
PARTE VII — PRESSÕES HISTÓRICAS . . . 43
41. Subitem de maior impacto por mês . . . 43
42. Subitens que mais vezes lideraram a pressão . . . 44
43. Maiores impactos históricos . . . 44
PARTE VIII — PERSISTÊNCIA DAS PRESSÕES . . . 45
44. Por que analisar persistência? . . . 45
45. Frequência no Top 20 de impacto . . . 45
PARTE IX — REPRESENTAÇÕES ANALÍTICAS . . . 48
46. Formato longo . . . 48
47. Matriz de variações . . . 48
48. Matriz de contribuições . . . 49
49. Matriz de impactos . . . 50
PARTE X — INDICADORES AGREGADOS . . . 51
50. Construir resumo mensal . . . 51
51. Estrutura dos indicadores . . . 52
52. O que cada indicador representa? . . . 53
PARTE XI — IMPLICAÇÕES PARA MODELAGEM . . . 53
53. Centenas de séries não significam centenas de boas features . . . 53
54. Representação agregada . . . 53
55. Possíveis sinais futuros . . . 54
56. Leakage temporal . . . 54
57. Conclusões . . . 54

Parte 0 — Granularidade ▪ Impacto ▪ Difusão ▪ Concentração ▪ Hierarquia

Este notebook representa o nível mais granular da decomposição do IPCA utilizada neste projeto.

A progressão construída até aqui é:

- 02.ipca → IPCA geral
- 02.01.grupos → grandes componentes
- 02.02.subgrupos → componentes intermediários
- 02.03.itens → categorias específicas
- 02.04.subitens → produtos e serviços detalhados

O notebook assume que:

- os pipelines já foram executados;

- `bcb.ipca_subitens` está atualizada;
- `bcb.ipca_itens` está atualizada;
- `bcb.ipca_subgrupos` está atualizada;
- `bcb.ipca_grupos` está atualizada;
- a auditoria dos dados foi concluída.

Este notebook NÃO executa pipelines e NÃO altera o banco de dados.

Objetivos

1. Entender o nível de subitem na hierarquia do IPCA.
2. Relacionar cada subitem ao item, subgrupo e grupo correspondentes.
3. Identificar produtos e serviços com movimentos extremos.
4. Calcular contribuição e impacto.
5. Identificar as principais pressões sobre a inflação.
6. Medir a difusão da inflação entre subitens.
7. Medir a concentração das pressões.
8. Analisar componentes específicos dentro de um item.
9. Verificar a consistência entre subitens e itens.
10. Preparar indicadores agregados para futura modelagem.

---

1. Hierarquia do IPCA

Neste projeto utilizamos:

```
grupo      -> código de 1 dígito
subgrupo   -> código de 2 dígitos
item       -> código de 4 dígitos
subitem    -> código de 7 dígitos
```

Portanto:

```
grupo
  |
  +-- subgrupo
         |
         +-- item
                |
                +-- subitem
                +-- subitem
                +-- subitem
```

Para um código de subitem com 7 dígitos:

- primeiro dígito identifica o grupo;

- dois primeiros identificam o subgrupo;
- quatro primeiros identificam o item;
- sete dígitos identificam o subitem.

2. O que representa um subitem?

O subitem representa o nível mais detalhado da estrutura analisada.

Exemplos típicos incluem produtos e serviços específicos.

Neste nível podemos investigar:

- choques específicos;
- alimentos;
- combustíveis;
- serviços;
- tarifas;
- produtos administrados;
- componentes com alta volatilidade.

Mas a maior granularidade produz também um desafio:

```
    mais detalhe
        |
        v
  mais componentes
        |
        v
maior dimensionalidade
```

Por isso, o foco deixa de ser visualizar todas as séries individualmente.

3. Estrutura matemática

Seja $\pi_{i,t}$ a variação mensal do subitem i no período t.

Seja $w_{i,t}$ seu peso publicado.

A contribuição aproximada é:

$$C_{i,t} = \pi_{i,t} \frac{w_{i,t}}{100}$$

A contribuição preserva a direção do efeito.

Para medir a magnitude da pressão utilizamos:

$$I_{i,t} = |C_{i,t}|$$

Portanto:

- indice → movimento dos preços
- peso → importância relativa
- contribuicao → efeito com direção
- impacto → magnitude da pressão

4. Configuração do ambiente

```
from pathlib import Path
import sys

PROJECT_ROOT = Path.cwd().resolve()

if PROJECT_ROOT.name == "notebooks":
    PROJECT_ROOT = PROJECT_ROOT.parent

if str(PROJECT_ROOT) not in sys.path:
    sys.path.insert(0, str(PROJECT_ROOT))

print("Project root:", PROJECT_ROOT)
```

```
Project root: /home/moacir/projects/ml/analytics/inflation
```

5. Importações

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from matplotlib.patches import Patch

from src.database.connection import engine

pd.set_option("display.max_columns", None)
pd.set_option("display.max_rows", 250)
pd.set_option("display.width", 220)
pd.set_option("display.float_format", "{:.4f}".format)
```

6. Carregar subitens do PostgreSQL

```
subitens = pd.read_sql(
    """
    SELECT
```

```
        date,
        categoria,
        categoria_nome,
        indice,
        peso
    FROM bcb.ipca_subitens
    ORDER BY date, categoria;
    """,
    engine,
)
```

6.1 Preparar dados

```
subitens["date"] = pd.to_datetime(
    subitens["date"]
)

subitens["categoria"] = (
    subitens["categoria"]
    .astype(str)
)

subitens = (
    subitens
    .sort_values(
        ["date", "categoria"]
    )
    .reset_index(drop=True)
)
```

6.2 Identificar níveis hierárquicos

```
subitens["grupo_codigo"] = (
    subitens["categoria"]
    .str[:1]
)

subitens["subgrupo_codigo"] = (
    subitens["categoria"]
    .str[:2]
)

subitens["item_codigo"] = (
    subitens["categoria"]
    .str[:4]
)
```

6.3 Contribuição e impacto

```
subitens["contribuicao"] = (
    subitens["indice"]
    * subitens["peso"]
    / 100
)

subitens["impacto"] = (
    subitens["contribuicao"]
    .abs()
)
```

6.4 Direção

```
subitens["direcao"] = np.select(
    [
        subitens["contribuicao"] > 0,
        subitens["contribuicao"] < 0,
    ],
    [
        "positiva",
        "negativa",
    ],
    default="neutra",
)

subitens.head(10)
```

	date	categoria	categoria_nome	indice	peso	grupo_codigo	subgrupo_codigo	ite
0	2020-01-01	1101002	Arroz	1.3100	0.4753	1	11	11
1	2020-01-01	1101051	Feijão - mulatinho	4.5000	0.0116	1	11	11
2	2020-01-01	1101052	Feijão - preto	-2.6800	0.0486	1	11	11
3	2020-01-01	1101053	Feijão - macáçar (fradinho)	5.3900	0.0121	1	11	11
4	2020-01-01	1101073	Feijão - carioca (rajado)	-0.7000	0.1350	1	11	11
5	2020-01-01	1101079	Milho (em grão)	0.2000	0.0100	1	11	11
6	2020-01-01	1102001	Farinha de arroz	1.2500	0.0028	1	11	11
7	2020-01-01	1102006	Macarrão	-0.1800	0.1467	1	11	11
8	2020-01-01	1102008	Fubá de milho	0.4300	0.0079	1	11	11
9	2020-01-01	1102010	Flocos de milho	-0.0300	0.0102	1	11	11

7. Carregar referências hierárquicas

```
grupos_ref = pd.read_sql(
    """
```

```
    SELECT DISTINCT
        categoria,
        categoria_nome
    FROM bcb.ipca_grupos
    ORDER BY categoria;
    """,
    engine,
)

subgrupos_ref = pd.read_sql(
    """
    SELECT DISTINCT
        categoria,
        categoria_nome
    FROM bcb.ipca_subgrupos
    ORDER BY categoria;
    """,
    engine,
)

itens_ref = pd.read_sql(
    """
    SELECT DISTINCT
        categoria,
        categoria_nome
    FROM bcb.ipca_itens
    ORDER BY categoria;
    """,
    engine,
)
```

7.1 Preparar referências

```
grupos_ref["categoria"] = (
    grupos_ref["categoria"]
    .astype(str)
)

subgrupos_ref["categoria"] = (
    subgrupos_ref["categoria"]
    .astype(str)
)

itens_ref["categoria"] = (
    itens_ref["categoria"]
    .astype(str)
)
```

```
grupos_ref = grupos_ref.rename(
    columns={
        "categoria": "grupo_codigo",
        "categoria_nome": "grupo_nome",
    }
)

subgrupos_ref = subgrupos_ref.rename(
    columns={
        "categoria": "subgrupo_codigo",
        "categoria_nome": "subgrupo_nome",
    }
)

itens_ref = itens_ref.rename(
    columns={
        "categoria": "item_codigo",
        "categoria_nome": "item_nome",
    }
)
```

7.2 Associar toda a hierarquia

```
subitens = (
    subitens
    .merge(
        grupos_ref,
        on="grupo_codigo",
        how="left",
        validate="many_to_one",
    )
    .merge(
        subgrupos_ref,
        on="subgrupo_codigo",
        how="left",
        validate="many_to_one",
    )
    .merge(
        itens_ref,
        on="item_codigo",
        how="left",
        validate="many_to_one",
    )
)

subitens[
    [
        "grupo_codigo",
```

```
        "grupo_nome",
        "subgrupo_codigo",
        "subgrupo_nome",
        "item_codigo",
        "item_nome",
        "categoria",
        "categoria_nome",
    ]
].drop_duplicates().head(20)
```

	grupo_codigo	grupo_nome	subgrupo_codigo	subgrupo_nome	item_codigo	item_
0	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
1	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
2	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
3	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
4	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
5	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
6	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
7	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
8	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
9	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
10	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
11	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
12	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
13	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
14	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
15	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
16	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
17	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
18	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
19	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér

8. Cobertura histórica

```
resumo = pd.DataFrame(
    [
        {
            "inicio": subitens["date"].min(),
            "fim": subitens["date"].max(),
            "observacoes": len(subitens),
            "subitens": subitens["categoria"].nunique(),
            "itens": subitens["item_codigo"].nunique(),
            "subgrupos": subitens["subgrupo_codigo"].nunique(),
            "grupos": subitens["grupo_codigo"].nunique(),
        }
```

```
    ]
)

resumo
```

	inicio	fim	observacoes	subitens	itens	subgrupos	grupos
0	2020-01-01	2026-08-01	30160	377	51	19	9

9. Catálogo hierárquico

No nível de subitens, o catálogo torna-se especialmente importante para navegar pela estrutura.

```
catalogo = (
    subitens[
        [
            "grupo_codigo",
            "grupo_nome",
            "subgrupo_codigo",
            "subgrupo_nome",
            "item_codigo",
            "item_nome",
            "categoria",
            "categoria_nome",
        ]
    ]
    .drop_duplicates()
    .sort_values(
        [
            "grupo_codigo",
            "subgrupo_codigo",
            "item_codigo",
            "categoria",
        ]
    )
    .reset_index(drop=True)
)

catalogo.head(20)
```

	grupo_codigo	grupo_nome	subgrupo_codigo	subgrupo_nome	item_codigo	item_
0	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
1	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
2	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
3	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
4	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai

	grupo_codigo	grupo_nome	subgrupo_codigo	subgrupo_nome	item_codigo	item_
5	1	Alimentação e bebidas	11	Alimentação no domicílio	1101	Cereai
6	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
7	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
8	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
9	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
10	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
11	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
12	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
13	1	Alimentação e bebidas	11	Alimentação no domicílio	1102	Farinh
14	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
15	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
16	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
17	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
18	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér
19	1	Alimentação e bebidas	11	Alimentação no domicílio	1103	Tubér

10. Quantidade de subitens por item

```
quantidade_por_item = (
    catalogo
    .groupby(
        [
            "grupo_nome",
            "subgrupo_nome",
            "item_codigo",
            "item_nome",
        ]
    )
    .size()
    .rename("subitens")
    .reset_index()
    .sort_values(
        "subitens",
        ascending=False,
    )
)

quantidade_por_item.head(20)
```

	grupo_nome	subgrupo_nome	item_codigo	item_nome
8	Alimentação e bebidas	Alimentação no domicílio	1108	Pescados
6	Alimentação e bebidas	Alimentação no domicílio	1106	Frutas
7	Alimentação e bebidas	Alimentação no domicílio	1107	Carnes
37	Saúde e cuidados pessoais	Produtos farmacêuticos e óticos	6101	Produtos farmacêuticos

	grupo_nome	subgrupo_nome	item_codigo	item_nome
43	Transportes	Transportes	5102	Veículo próprio
34	Habitação	Encargos e manutenção	2103	Reparos
24	Despesas pessoais	Recreação e fumo	7201	Recreação
36	Saúde e cuidados pessoais	Cuidados pessoais	6301	Higiene pessoal
16	Alimentação e bebidas	Alimentação no domicílio	1116	Sal e condimentos
35	Habitação	Encargos e manutenção	2104	Artigos de limpeza
14	Alimentação e bebidas	Alimentação no domicílio	1114	Bebidas e infusões
42	Transportes	Transportes	5101	Transporte público
26	Despesas pessoais	Serviços pessoais	7101	Serviços pessoais
3	Alimentação e bebidas	Alimentação no domicílio	1103	Tubérculos, raízes e legumes
0	Alimentação e bebidas	Alimentação fora do domicílio	1201	Alimentação fora do domicílio
15	Alimentação e bebidas	Alimentação no domicílio	1115	Enlatados e conservas
2	Alimentação e bebidas	Alimentação no domicílio	1102	Farinhas, féculas e massas
4	Alimentação e bebidas	Alimentação no domicílio	1104	Açúcares e derivados
9	Alimentação e bebidas	Alimentação no domicílio	1109	Carnes e peixes industrializados
27	Educação	Cursos, leitura e papelaria	8101	Cursos regulares

---

PARTE I — ÚLTIMO MÊS

11. Último mês disponível

```
ultimo_mes = subitens["date"].max()

subitens_ultimo = (
    subitens[
        subitens["date"] == ultimo_mes
    ]
    .copy()
)

print(
    "Último mês disponível:",
    ultimo_mes.strftime("%Y-%m"),
)

print(
    "Subitens disponíveis:",
    len(subitens_ultimo),
)
```

```
Último mês disponível: 2026-08
Subitens disponíveis: 377
```

12. Subitens com maior peso

A maior granularidade permite observar quais produtos e serviços específicos possuem maior relevância relativa na estrutura do índice.

```
subitens_ultimo[
    [
        "grupo_nome",
        "subgrupo_nome",
        "item_nome",
        "categoria_nome",
        "peso",
    ]
].sort_values(
    "peso",
    ascending=False,
).head(30)
```

	grupo_nome	subgrupo_nome	item_nome	categoria_nor
30069	Transportes	Transportes	Combustíveis (veículos)	Gasolina
29982	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétri
30096	Saúde e cuidados pessoais	Serviços de saúde	Plano de saúde	Plano de saúd
29951	Habitação	Encargos e manutenção	Aluguel e taxas	Aluguel reside
29942	Alimentação e bebidas	Alimentação fora do domicílio	Alimentação fora do domicílio	Refeição
30055	Transportes	Transportes	Veículo próprio	Automóvel no
30111	Despesas pessoais	Serviços pessoais	Serviços pessoais	Empregado d
30056	Transportes	Transportes	Veículo próprio	Emplacament
29952	Habitação	Encargos e manutenção	Aluguel e taxas	Condomínio
29943	Alimentação e bebidas	Alimentação fora do domicílio	Alimentação fora do domicílio	Lanche
29953	Habitação	Encargos e manutenção	Aluguel e taxas	Taxa de água
30062	Transportes	Transportes	Veículo próprio	Conserto de a
30135	Educação	Cursos, leitura e papelaria	Cursos regulares	Ensino fundar
30116	Despesas pessoais	Serviços pessoais	Serviços pessoais	Serviço bancá
30137	Educação	Cursos, leitura e papelaria	Cursos regulares	Ensino superi
30065	Transportes	Transportes	Veículo próprio	Automóvel us
30159	Comunicação	Comunicação	Comunicação	Combo de tel
30154	Comunicação	Comunicação	Comunicação	Plano de telef
29980	Habitação	Combustíveis e energia	Combustíveis (domésticos)	Gás de botijã
30103	Saúde e cuidados pessoais	Cuidados pessoais	Higiene pessoal	Perfume
30112	Despesas pessoais	Serviços pessoais	Serviços pessoais	Cabeleireiro e
30045	Transportes	Transportes	Transporte público	Ônibus urban
29903	Alimentação e bebidas	Alimentação no domicílio	Panificados	Pão francês
30050	Transportes	Transportes	Transporte público	Passagem aér
29894	Alimentação e bebidas	Alimentação no domicílio	Leites e derivados	Leite longa vi
30057	Transportes	Transportes	Veículo próprio	Seguro volunt
30157	Comunicação	Comunicação	Comunicação	Aparelho tele
30097	Saúde e cuidados pessoais	Cuidados pessoais	Higiene pessoal	Produto para
30128	Despesas pessoais	Recreação e fumo	Recreação	Hospedagem

	grupo_nome	subgrupo_nome	item_nome	categoria_no
30018	Vestuário	Roupas	Roupa masculina	Camisa/camis

13. Maiores variações positivas

Esta análise considera apenas $\pi_{i,t}$.

Uma variação muito alta não significa necessariamente grande impacto, pois o peso do componente pode ser pequeno.

```
subitens_ultimo[
    [
        "grupo_nome",
        "subgrupo_nome",
        "item_nome",
        "categoria_nome",
        "indice",
        "peso",
        "contribuicao",
        "impacto",
    ]
].nlargest(
    25,
    "indice",
)
```

	grupo_nome	subgrupo_nome	item_nome	categoria_nome
29830	Alimentação e bebidas	Alimentação no domicílio	Frutas	Limão
30132	Despesas pessoais	Recreação e fumo	Fumo	Cigarro
29834	Alimentação e bebidas	Alimentação no domicílio	Frutas	Maracujá
29803	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Pimentão
29869	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - serra
29845	Alimentação e bebidas	Alimentação no domicílio	Carnes	Carne de carneiro
29858	Alimentação e bebidas	Alimentação no domicílio	Carnes	Capa de filé
29873	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - palombeta
29822	Alimentação e bebidas	Alimentação no domicílio	Frutas	Banana-da-terra
29875	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - salmão
30125	Despesas pessoais	Recreação e fumo	Recreação	Casa noturna
29887	Alimentação e bebidas	Alimentação no domicílio	Carnes e peixes industrializados	Salame
29864	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - sardinha
30072	Transportes	Transportes	Combustíveis (veículos)	Gás veicular
29880	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - peroá
29924	Alimentação e bebidas	Alimentação no domicílio	Enlatados e conservas	Pepino em conserva
29927	Alimentação e bebidas	Alimentação no domicílio	Enlatados e conservas	Sopa desidratada
30009	Artigos de residência	Consertos e manutenção	Consertos e manutenção	Conserto de televisc
29957	Habitação	Encargos e manutenção	Reparos	Vidro

	grupo_nome	subgrupo_nome	item_nome	categoria_nome
29968	Habitação	Encargos e manutenção	Artigos de limpeza	Saco para lixo
29835	Alimentação e bebidas	Alimentação no domicílio	Frutas	Melancia
29867	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - cação
29857	Alimentação e bebidas	Alimentação no domicílio	Carnes	Peito
29827	Alimentação e bebidas	Alimentação no domicílio	Frutas	Banana - prata
29979	Habitação	Combustíveis e energia	Combustíveis (domésticos)	Carvão vegetal

14. Maiores variações negativas

```
subitens_ultimo[
    [
        "grupo_nome",
        "subgrupo_nome",
        "item_nome",
        "categoria_nome",
        "indice",
        "peso",
        "contribuicao",
        "impacto",
    ]
].nsmallest(
    25,
    "indice",
)
```

	grupo_nome	subgrupo_nome	item_nome	categoria_nom
29798	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Batata-inglesa
30050	Transportes	Transportes	Transporte público	Passagem aére
29802	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Pepino
29806	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Cenoura
29805	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Cebola
29804	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Tomate
29913	Alimentação e bebidas	Alimentação no domicílio	Bebidas e infusões	Açaí (emulsão
29841	Alimentação e bebidas	Alimentação no domicílio	Frutas	Morango
29818	Alimentação e bebidas	Alimentação no domicílio	Hortaliças e verduras	Couve-flor
29801	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Abobrinha
29819	Alimentação e bebidas	Alimentação no domicílio	Hortaliças e verduras	Repolho
29982	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétric
29879	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - filhote
29829	Alimentação e bebidas	Alimentação no domicílio	Frutas	Laranja - lima
29842	Alimentação e bebidas	Alimentação no domicílio	Frutas	Goiaba
29787	Alimentação e bebidas	Alimentação no domicílio	Cereais, leguminosas e oleaginosas	Feijão - carioc
30053	Transportes	Transportes	Transporte público	Transporte po
29828	Alimentação e bebidas	Alimentação no domicílio	Frutas	Laranja - baía

	grupo_nome	subgrupo_nome	item_nome	categoria_nom
29893	Alimentação e bebidas	Alimentação no domicílio	Aves e ovos	Ovo de galinh
29821	Alimentação e bebidas	Alimentação no domicílio	Hortaliças e verduras	Brócolis
30070	Transportes	Transportes	Combustíveis (veículos)	Etanol
29797	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Batata-doce
30091	Saúde e cuidados pessoais	Serviços de saúde	Serviços médicos e dentários	Fisioterapeuta
29878	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - dourad
29824	Alimentação e bebidas	Alimentação no domicílio	Frutas	Abacate

15. Principais pressões

Quando falamos em pressão, utilizamos preferencialmente o impacto:

$$I_{i,t} = |C_{i,t}|$$

Assim, contribuições positivas e negativas competem no mesmo ranking pela magnitude.

```
ranking_impacto = (
    subitens_ultimo[
        [
            "grupo_nome",
            "subgrupo_nome",
            "item_nome",
            "categoria_nome",
            "indice",
            "peso",
            "contribuicao",
            "impacto",
            "direcao",
        ]
    ]
    .sort_values(
        "impacto",
        ascending=False,
    )
    .reset_index(drop=True)
)

ranking_impacto.head(20)
```

	grupo_nome	subgrupo_nome	item_nome	categoria_nome
0	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica r
1	Despesas pessoais	Recreação e fumo	Fumo	Cigarro
2	Transportes	Transportes	Transporte público	Passagem aérea
3	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Batata-inglesa

	grupo_nome	subgrupo_nome	item_nome	categoria_nome
4	Transportes	Transportes	Combustíveis (veículos)	Gasolina
5	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Tomate
6	Transportes	Transportes	Veículo próprio	Conserto de auto
7	Transportes	Transportes	Combustíveis (veículos)	Etanol
8	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Cebola
9	Saúde e cuidados pessoais	Serviços de saúde	Plano de saúde	Plano de saúde
10	Despesas pessoais	Serviços pessoais	Serviços pessoais	Empregado dom
11	Habitação	Encargos e manutenção	Aluguel e taxas	Condomínio
12	Transportes	Transportes	Veículo próprio	Automóvel novo
13	Alimentação e bebidas	Alimentação no domicílio	Leites e derivados	Leite longa vida
14	Transportes	Transportes	Transporte público	Transporte por a
15	Habitação	Encargos e manutenção	Aluguel e taxas	Aluguel residenci
16	Alimentação e bebidas	Alimentação fora do domicílio	Alimentação fora do domicílio	Lanche
17	Alimentação e bebidas	Alimentação no domicílio	Frutas	Limão
18	Alimentação e bebidas	Alimentação no domicílio	Aves e ovos	Ovo de galinha
19	Alimentação e bebidas	Alimentação no domicílio	Bebidas e infusões	Café moído

16. Gráfico das principais pressões

O comprimento da barra representa $I_{i,t}$.

A cor recupera o sinal de $C_{i,t}$:

- vermelho -> contribuição positiva;
- azul -> contribuição negativa.

```
top_impacto = (
    ranking_impacto
    .head(15)
    .sort_values("impacto")
)

cores = np.where(
    top_impacto["contribuicao"] >= 0,
    "tab:red",
    "tab:blue",
)

plt.figure(figsize=(10, 5))

plt.barh(
    top_impacto["categoria_nome"],
    top_impacto["impacto"],
    color=cores,
)

plt.title(
```

```
    f"IPCA - Principais Pressões por Subitem - {ultimo_mes:%Y-%m}"
)

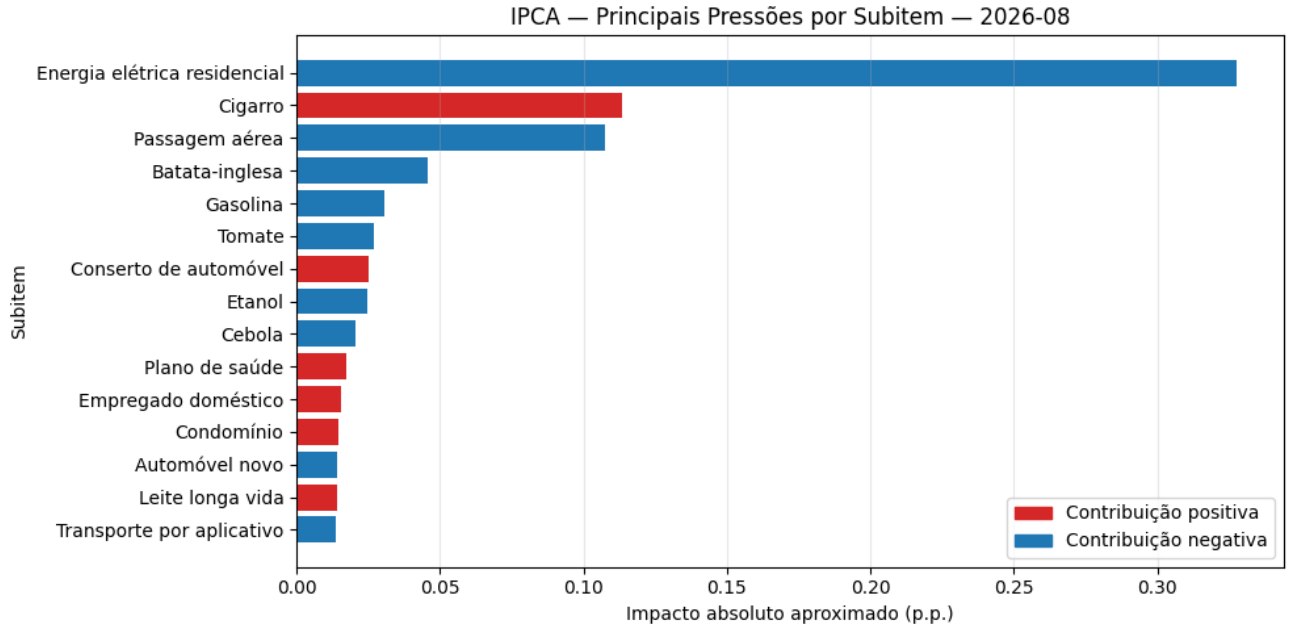
plt.xlabel("Impacto absoluto aproximado (p.p.)")
plt.ylabel("Subitem")

plt.grid(
    True,
    axis="x",
    alpha=0.3,
)

legenda = [
    Patch(
        color="tab:red",
        label="Contribuição positiva",
    ),
    Patch(
        color="tab:blue",
        label="Contribuição negativa",
    ),
]

plt.legend(
    handles=legenda,
    loc="lower right",
)

plt.tight_layout()
plt.show()
```



17. Direção das principais pressões

O impacto mostra magnitude.

A contribuição recupera a direção:

$$C_{i,t} = \pi_{i,t} \frac{w_{i,t}}{100}$$

```
top_pressao_direcao = (
    subitens_ultimo
    .sort_values(
        "impacto",
        ascending=False,
    )
    .head(20)
    .sort_values("contribuicao")
)

plt.figure(figsize=(10, 5))

plt.barh(
    top_pressao_direcao["categoria_nome"],
    top_pressao_direcao["contribuicao"],
)

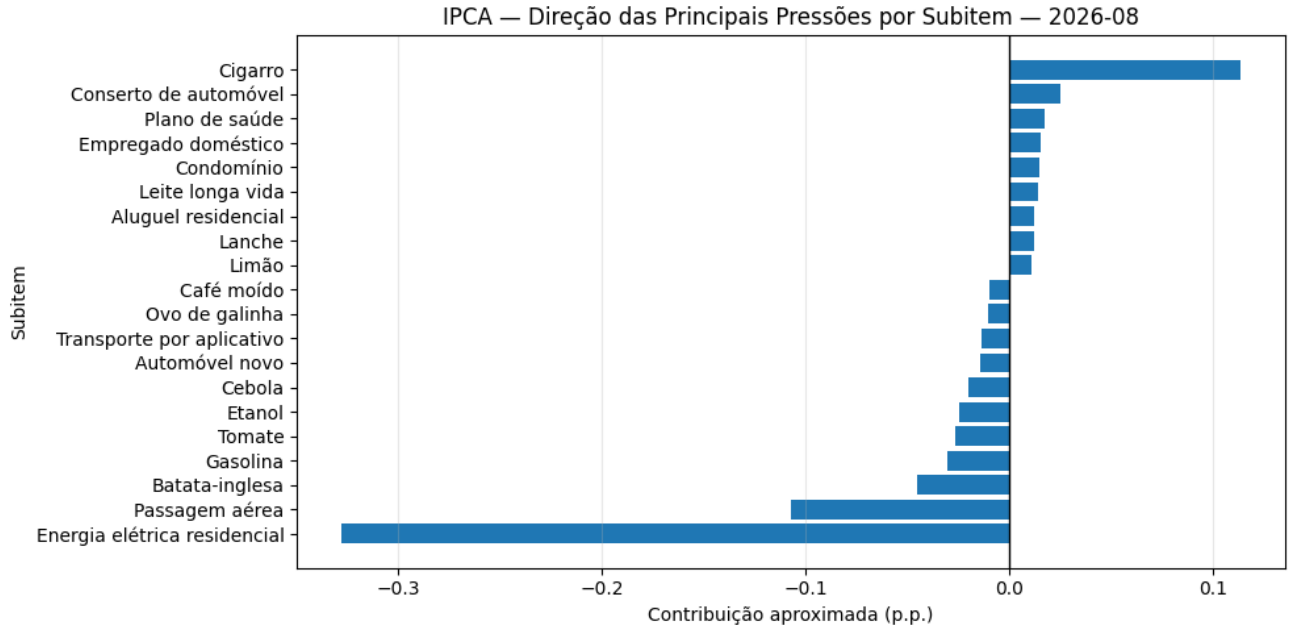
plt.axvline(
    0,
    color="black",
    linewidth=1,
)

plt.title(
    f"IPCA - Direção das Principais Pressões por Subitem - {ultimo_mes:%Y-%m}"
)

plt.xlabel("Contribuição aproximada (p.p.)")
plt.ylabel("Subitem")

plt.grid(
    True,
    axis="x",
    alpha=0.3,
)

plt.tight_layout()
plt.show()
```



PARTE II — DISTRIBUIÇÃO DOS MOVIMENTOS

18. Distribuição das variações

Com centenas de componentes, a distribuição das variações passa a fornecer uma visão mais adequada do conjunto que um gráfico com centenas de séries.

```
plt.figure(figsize=(10, 3.5))

sns.histplot(
    subitens_ultimo["indice"],
    bins=50,
    kde=True,
)

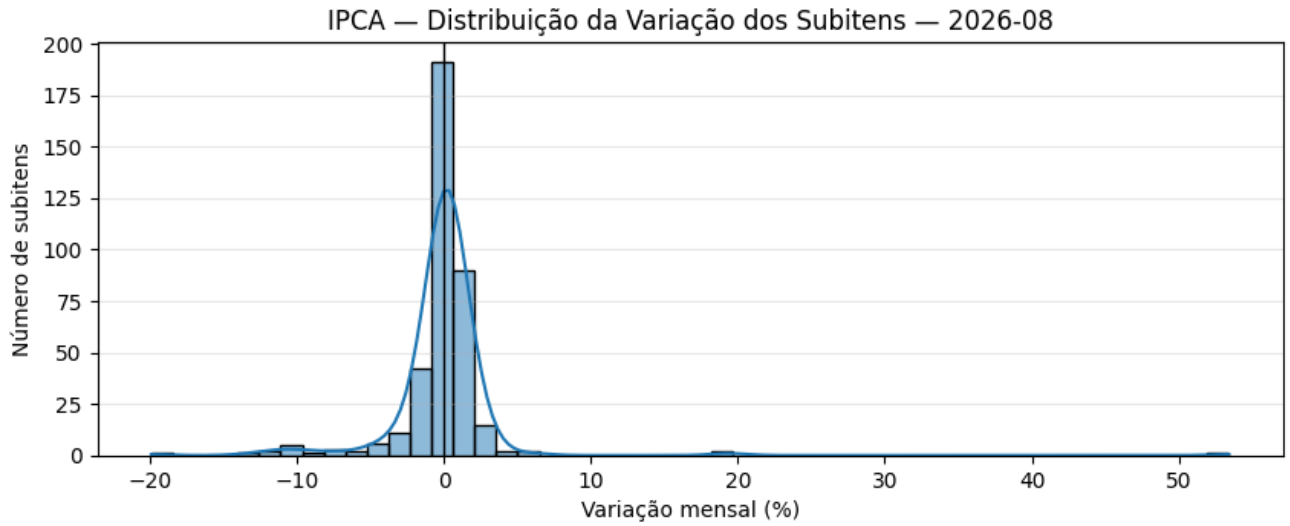
plt.axvline(
    0,
    color="black",
    linewidth=1,
)

plt.title(
    f"IPCA - Distribuição da Variação dos Subitens - {ultimo_mes:%Y-%m}"
)

plt.xlabel("Variação mensal (%)")
plt.ylabel("Número de subitens")
```

```
plt.grid(
    True,
    axis="y",
    alpha=0.3,
)

plt.show()
```



19. Estatísticas da distribuição

```
subitens_ultimo["indice"].describe()
```

```
count   377.0000
mean     -0.0433
std       3.9776
min     -19.8900
25%      -0.5100
50%       0.1300
75%       0.7300
max      53.4000
Name: indice, dtype: float64
```

20. Dispersão

A amplitude é definida por:

$$A_t = \max_i(\pi_{i,t}) - \min_i(\pi_{i,t})$$

Como a amplitude é sensível a valores extremos, também calculamos o intervalo interquartil:

$$IQR_t = Q_{0.75,t} - Q_{0.25,t}$$

```
q1 = (
    subitens_ultimo["indice"]
    .quantile(0.25)
)

q3 = (
    subitens_ultimo["indice"]
    .quantile(0.75)
)

dispersao_atual = pd.DataFrame(
    [
        {
            "media": subitens_ultimo["indice"].mean(),
            "mediana": subitens_ultimo["indice"].median(),
            "desvio_padrao": subitens_ultimo["indice"].std(),
            "q1": q1,
            "q3": q3,
            "iqr": q3 - q1,
            "minimo": subitens_ultimo["indice"].min(),
            "maximo": subitens_ultimo["indice"].max(),
            "amplitude": (
                subitens_ultimo["indice"].max()
                - subitens_ultimo["indice"].min()
            ),
        }
    ]
)

dispersao_atual
```

	media	mediana	desvio_padrao	q1	q3	iqr	minimo	maximo	amplitude
0	-0.0433	0.1300	3.9776	-0.5100	0.7300	1.2400	-19.8900	53.4000	73.2900

21. Valores extremos

Valores extremos de `indice` não devem ser interpretados isoladamente.

Devemos verificar simultaneamente:

```
indice
peso
impacto
```

```
extremos_positivos = (
    subitens_ultimo
    .nlargest(
        10,
        "indice",
    )[
        [
            "grupo_nome",
            "subgrupo_nome",
            "item_nome",
            "categoria_nome",
            "indice",
            "peso",
            "contribuicao",
            "impacto",
        ]
    ]
)

extremos_positivos
```

	grupo_nome	subgrupo_nome	item_nome	categoria_nome	inc
29830	Alimentação e bebidas	Alimentação no domicílio	Frutas	Limão	53.
30132	Despesas pessoais	Recreação e fumo	Fumo	Cigarro	19.
29834	Alimentação e bebidas	Alimentação no domicílio	Frutas	Maracujá	19.
29803	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Pimentão	6.2
29869	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - serra	5.7
29845	Alimentação e bebidas	Alimentação no domicílio	Carnes	Carne de carneiro	3.7
29858	Alimentação e bebidas	Alimentação no domicílio	Carnes	Capa de filé	3.6
29873	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - palombeta	3.1
29822	Alimentação e bebidas	Alimentação no domicílio	Frutas	Banana-da-terra	2.9
29875	Alimentação e bebidas	Alimentação no domicílio	Pescados	Peixe - salmão	2.9

```
extremos_negativos = (
    subitens_ultimo
    .nsmallest(
        10,
        "indice",
    )[
        [
            "grupo_nome",
            "subgrupo_nome",
            "item_nome",
            "categoria_nome",
            "indice",
            "peso",
            "contribuicao",
```

```
            "impacto",
        ]
    ]
)

extremos_negativos
```

	grupo_nome	subgrupo_nome	item_nome	categoria_nome	indic
29798	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Batata-inglesa	-19.8
30050	Transportes	Transportes	Transporte público	Passagem aérea	-13.1
29802	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Pepino	-12.3
29806	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Cenoura	-11.2
29805	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Cebola	-11.0
29804	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Tomate	-10.9
29913	Alimentação e bebidas	Alimentação no domicílio	Bebidas e infusões	Açaí (emulsão)	-10.4
29841	Alimentação e bebidas	Alimentação no domicílio	Frutas	Morango	-9.94
29818	Alimentação e bebidas	Alimentação no domicílio	Hortaliças e verduras	Couve-flor	-9.63
29801	Alimentação e bebidas	Alimentação no domicílio	Tubérculos, raízes e legumes	Abobrinha	-8.88

Interpretação

Um subitem pode apresentar uma variação extremamente elevada e, ainda assim, produzir impacto pequeno sobre o IPCA.

Isso ocorre porque:

$$I_{i,t} = \left| \pi_{i,t} \frac{w_{i,t}}{100} \right|$$

Portanto, variação e relevância econômica não são equivalentes.

PARTE III — DIFUSÃO

22. Definição

Seja N_t o número de subitens observados no período t.

A difusão é:

$$D_t = \frac{\sum_{i=1}^{N_t} \mathbf{1}\left(\pi_{i,t} > 0\right)}{N_t}$$

Portanto, D_t representa a proporção de subitens com variação positiva naquele mês.

A difusão NÃO considera peso ou magnitude.

23. Calcular difusão

```
difusao_subitens = (
    subitens
    .assign(
        positivo=(
            subitens["indice"] > 0
        )
    )
    .groupby("date")
    .agg(
        subitens=(
            "categoria",
            "count",
        ),
        positivos=(
            "positivo",
            "sum",
        ),
    )
)

difusao_subitens["difusao"] = (
    difusao_subitens["positivos"]
    / difusao_subitens["subitens"]
)

difusao_subitens.tail(12)
```

date	subitens	positivos	difusao
2025-09-01	377	197	0.5225
2025-10-01	377	197	0.5225
2025-11-01	377	210	0.5570
2025-12-01	377	228	0.6048
2026-01-01	377	241	0.6393
2026-02-01	377	231	0.6127
2026-03-01	377	254	0.6737
2026-04-01	377	246	0.6525
2026-05-01	377	245	0.6499
2026-06-01	377	202	0.5358
2026-07-01	377	187	0.4960
2026-08-01	377	205	0.5438

24. Difusão no último mês

```
difusao_atual = (
    difusao_subitens
    .loc[[ultimo_mes]]
    .copy()
)

difusao_atual["difusao_pct"] = (
    difusao_atual["difusao"]
    * 100
)

difusao_atual
```

date	subitens	positivos	difusao	difusao_pct
2026-08-01	377	205	0.5438	54.3767

25. Evolução recente da difusão

```
data_inicio_10a = (
    subitens["date"].max()
    - pd.DateOffset(years=10)
)

difusao_10a = (
    difusao_subitens[
        difusao_subitens.index
        >= data_inicio_10a
    ]
)

plt.figure(figsize=(10, 3.5))

plt.plot(
    difusao_10a.index,
    difusao_10a["difusao"] * 100,
)

plt.axhline(
    50,
    color="black",
    linewidth=1,
    alpha=0.5,
```

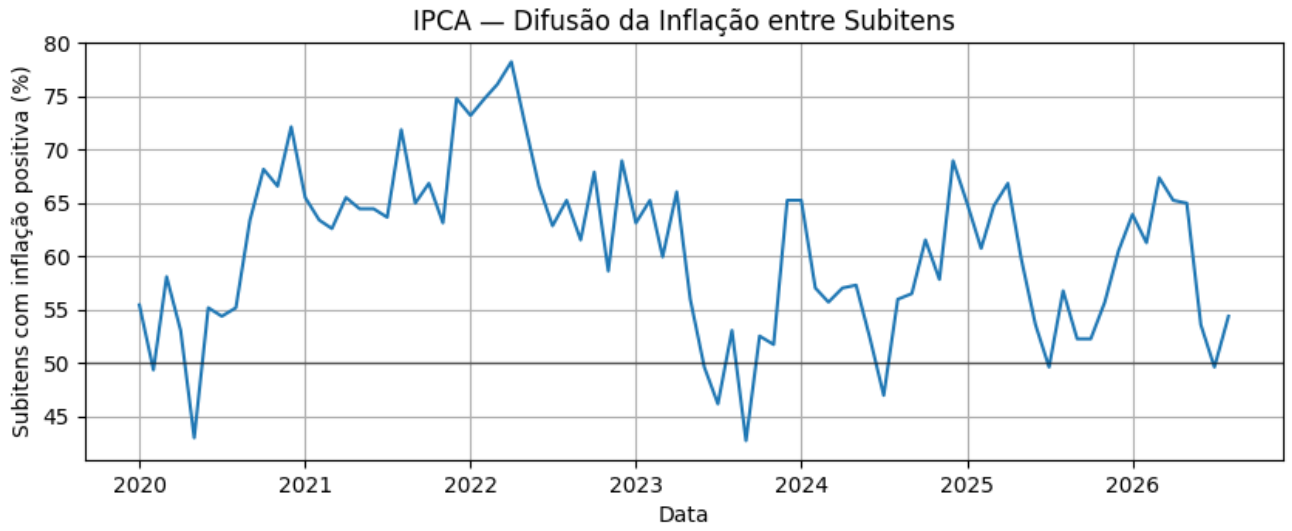
```
)

plt.title(
    "IPCA - Difusão da Inflação entre Subitens"
)

plt.xlabel("Data")
plt.ylabel("Subitens com inflação positiva (%)")

plt.grid(True)

plt.show()
```



26. Interpretação

A difusão permite distinguir:

```
inflação disseminada
        vs.
inflação concentrada
```

Uma difusão de 80%, por exemplo, significa que 8 em cada 10 subitens observados apresentaram variação positiva.

Isso não significa que os componentes tenham a mesma importância econômica.

PARTE IV — CONCENTRAÇÃO DAS PRESSÕES

27. Impacto total

Definimos:

$$I_t^{total} = \sum_{i=1}^{N_t} I_{i,t}$$

Importante:

$$I_t^{total} \neq IPCA_t$$

pois os impactos removem os sinais das contribuições.

```
impacto_mensal = (
    subitens
    .groupby(
        "date",
        as_index=False,
    )["impacto"]
    .sum()
    .rename(
        columns={
            "impacto":
            "impacto_total"
        }
    )
)

impacto_mensal.tail(12)
```

	date	impacto_total
68	2025-09-01	1.1188
69	2025-10-01	0.6823
70	2025-11-01	0.8023
71	2025-12-01	0.9141
72	2026-01-01	1.1381
73	2026-02-01	1.1120
74	2026-03-01	1.1340
75	2026-04-01	1.1176
76	2026-05-01	1.0302
77	2026-06-01	0.6509
78	2026-07-01	1.0087
79	2026-08-01	1.2264

28. Concentração nos maiores impactos

Com muitos subitens, usar apenas os 5 maiores pode representar uma parcela muito pequena da estrutura.

Por isso calcularemos:

- Top 5;
- Top 10;
- Top 20.

Para k componentes:

$$K_{k,t} = \frac{\sum_{i \in TopK_t} I_{i,t}}{\sum_i I_{i,t}}$$

```
def concentracao_top_n(grupo, n):

    impactos = (
        grupo["impacto"]
        .sort_values(
            ascending=False
        )
    )

    total = impactos.sum()

    if total == 0:
        return 0.0

    return (
        impactos.head(n).sum()
        / total
    )
```

```
concentracao = pd.DataFrame(
    {
        "top5": (
            subitens
            .groupby("date")
            .apply(
                concentracao_top_n,
                n=5,
                include_groups=False,
            )
        ),
        "top10": (
            subitens
            .groupby("date")
```

```
            .apply(
                concentracao_top_n,
                n=10,
                include_groups=False,
            )
        ),
        "top20": (
            subitens
            .groupby("date")
            .apply(
                concentracao_top_n,
                n=20,
                include_groups=False,
            )
        ),
    }
)

concentracao.tail(12)
```

date	top5	top10	top20
2025-09-01	0.4867	0.5597	0.6671
2025-10-01	0.2953	0.4031	0.5695
2025-11-01	0.2831	0.4097	0.5516
2025-12-01	0.3319	0.4487	0.5881
2026-01-01	0.3515	0.5122	0.6632
2026-02-01	0.3202	0.4291	0.5670
2026-03-01	0.3804	0.4661	0.6123
2026-04-01	0.3392	0.4252	0.5575
2026-05-01	0.4069	0.5310	0.6337
2026-06-01	0.2744	0.3834	0.5203
2026-07-01	0.4387	0.5300	0.6570
2026-08-01	0.5093	0.6022	0.7058

29. Evolução da concentração

```
concentracao_10a = (
    concentracao[
        concentracao.index
        >= data_inicio_10a
    ]
)

plt.figure(figsize=(10, 5))
```

```
plt.plot(
    concentracao_10a.index,
    concentracao_10a["top5"] * 100,
    label="Top 5",
)

plt.plot(
    concentracao_10a.index,
    concentracao_10a["top10"] * 100,
    label="Top 10",
)

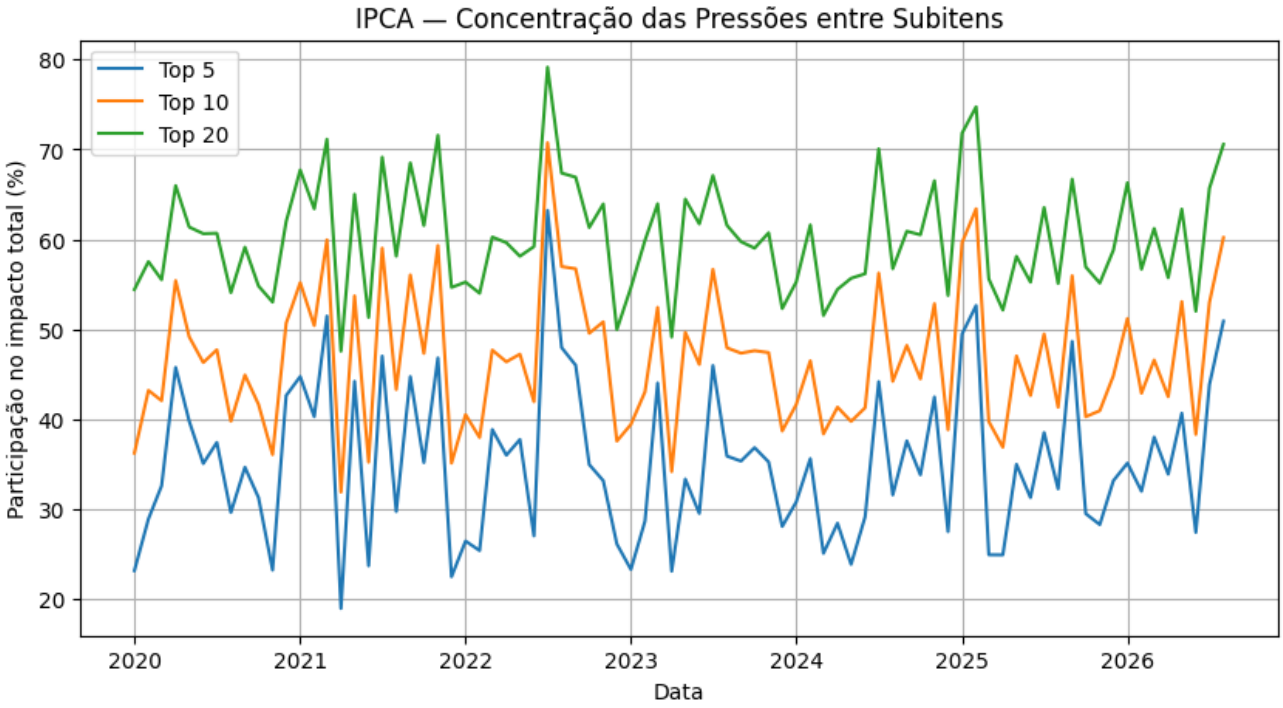
plt.plot(
    concentracao_10a.index,
    concentracao_10a["top20"] * 100,
    label="Top 20",
)

plt.title(
    "IPCA - Concentração das Pressões entre Subitens"
)

plt.xlabel("Data")
plt.ylabel("Participação no impacto total (%)")

plt.legend()
plt.grid(True)

plt.show()
```



30. Difusão versus concentração

As medidas capturam dimensões diferentes.

- difusão → quantos componentes estão aumentando?
- concentração → poucos componentes dominam as pressões?

Por exemplo:

- **Alta difusão + baixa concentração**
  Muitos preços subindo e impactos distribuídos.
- **Baixa difusão + alta concentração**
  Poucos componentes dominam os movimentos.

Essa distinção pode ser muito útil para caracterizar regimes inflacionários.

PARTE V — ANÁLISE DENTRO DE UM ITEM

31. Selecionar item

No nível de subitens, a análise individual deve ser feita dentro do item-pai.

```
selecionar item
      |
      v
analisar seus subitens
```

```
item_escolhido = (
    itens_ref
    .sort_values("item_codigo")
    .iloc[0]["item_nome"]
)

item_escolhido
```

```
'Cereais, leguminosas e oleaginosas'
```

O item pode ser definido explicitamente:

```
item_escolhido = "Carnes"
```

```
subitens_item = (
    subitens[
        subitens["item_nome"]
        == item_escolhido
    ]
    .copy()
)

subitens_item[
    [
        "categoria",
        "categoria_nome",
    ]
].drop_duplicates()
```

	categoria	categoria_nome
0	1101002	Arroz
1	1101051	Feijão - mulatinho
2	1101052	Feijão - preto
3	1101053	Feijão - macáçar (fradinho)
4	1101073	Feijão - carioca (rajado)
5	1101079	Milho (em grão)

32. Subitens do item no último mês

```
subitens_item_ultimo = (
    subitens_item[
        subitens_item["date"]
        == ultimo_mes
    ]
    .sort_values(
        "impacto",
        ascending=False,
    )
)

subitens_item_ultimo[
    [
        "categoria_nome",
        "indice",
        "peso",
        "contribuicao",
        "impacto",
        "direcao",
    ]
]
```

	categoria_nome	indice	peso	contribuicao	impacto	direcao
29787	Feijão - carioca (rajado)	-4.8200	0.1440	-0.0069	0.0069	negativa
29783	Arroz	1.3400	0.5018	0.0067	0.0067	positiva
29785	Feijão - preto	-0.6300	0.0434	-0.0003	0.0003	negativa
29786	Feijão - macáçar (fradinho)	-1.2000	0.0163	-0.0002	0.0002	negativa
29788	Milho (em grão)	-1.0400	0.0125	-0.0001	0.0001	negativa
29784	Feijão - mulatinho	0.1100	0.0135	0.0000	0.0000	positiva

33. Pressões dentro do item

O comprimento da barra representa impacto.

A cor representa a direção da contribuição.

```
pressao_item = (
    subitens_item_ultimo
    .sort_values("impacto")
)

cores = np.where(
    pressao_item["contribuicao"] >= 0,
    "tab:red",
    "tab:blue",
)
```

```
plt.figure(
    figsize=(
        10,
        max(
            5,
            len(pressao_item) * 0.35,
        ),
    )
)

plt.barh(
    pressao_item["categoria_nome"],
    pressao_item["impacto"],
    color=cores,
)

plt.title(
    f"IPCA - Pressões nos Subitens de {item_escolhido}"
)

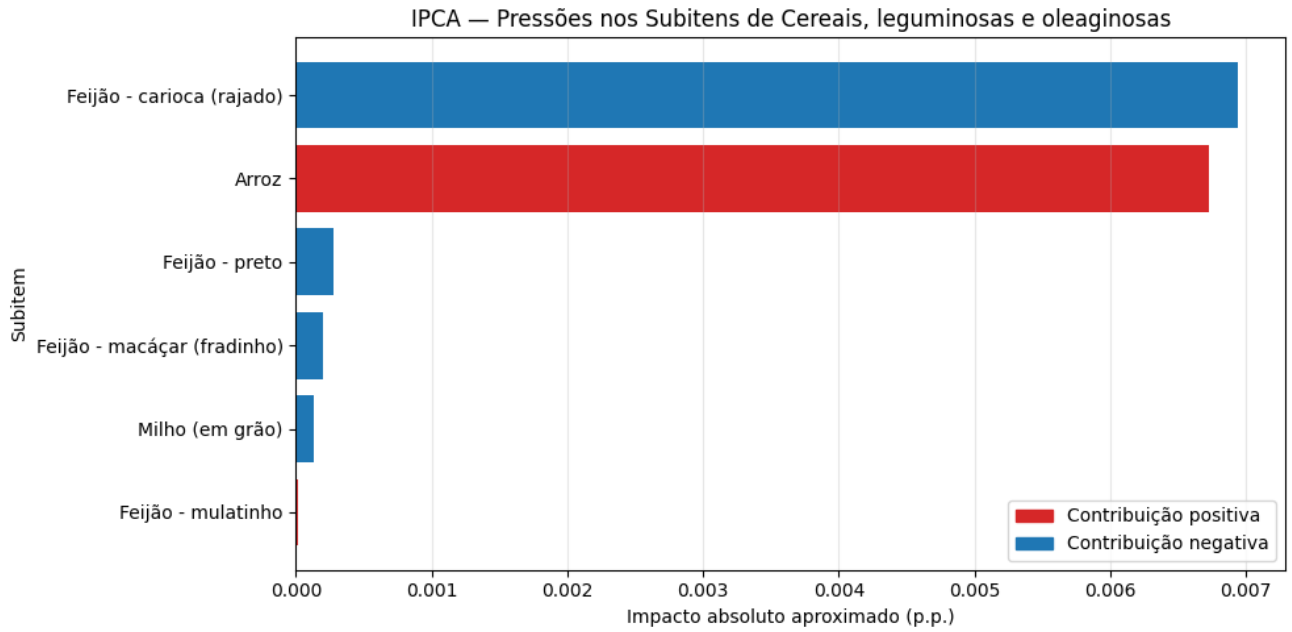
plt.xlabel("Impacto absoluto aproximado (p.p.)")
plt.ylabel("Subitem")

plt.grid(
    True,
    axis="x",
    alpha=0.3,
)

legenda = [
    Patch(
        color="tab:red",
        label="Contribuição positiva",
    ),
    Patch(
        color="tab:blue",
        label="Contribuição negativa",
    ),
]

plt.legend(
    handles=legenda,
    loc="lower right",
)

plt.tight_layout()
plt.show()
```



34. Direção das pressões dentro do item

```
direcao_item = (
    subitens_item_ultimo
    .sort_values("contribuicao")
)

plt.figure(
    figsize=(
        10,
        max(
            5,
            len(direcao_item) * 0.35,
        ),
    )
)

plt.barh(
    direcao_item["categoria_nome"],
    direcao_item["contribuicao"],
)

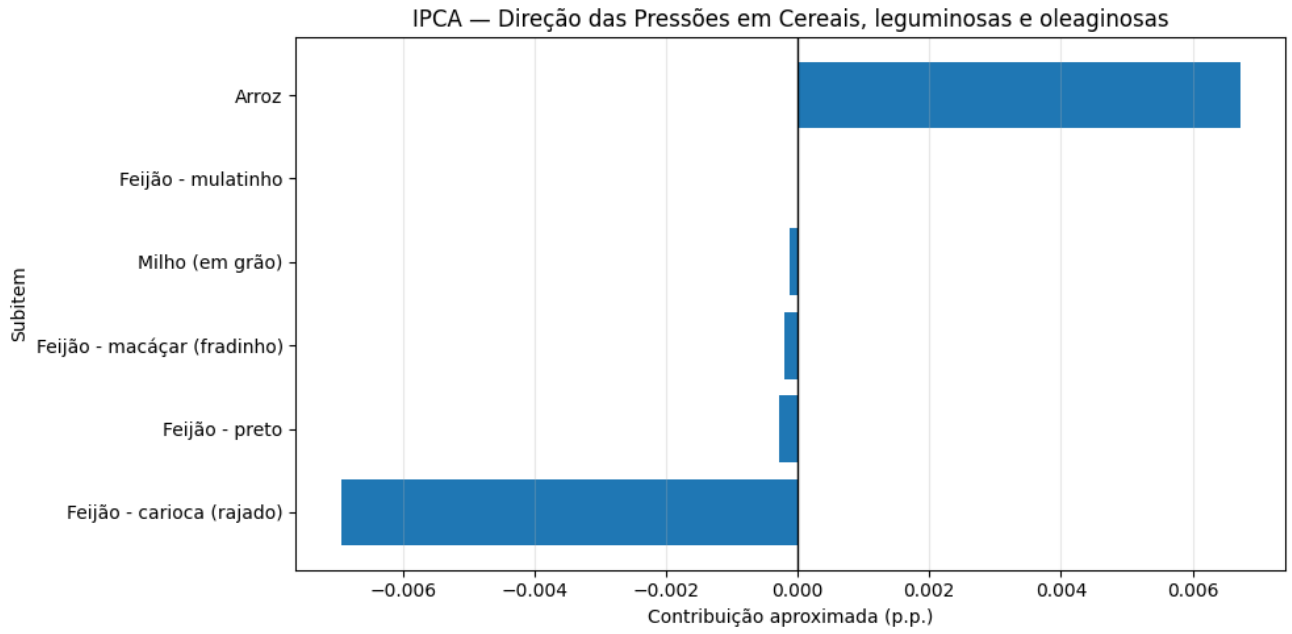
plt.axvline(
    0,
    color="black",
    linewidth=1,
)
```

```
plt.title(
    f"IPCA - Direção das Pressões em {item_escolhido}"
)

plt.xlabel("Contribuição aproximada (p.p.)")
plt.ylabel("Subitem")

plt.grid(
    True,
    axis="x",
    alpha=0.3,
)

plt.tight_layout()
plt.show()
```



PARTE VI — CONSISTÊNCIA COM OS ITENS

35. Relação hierárquica

Seja j um item e $i \in j$ seus subitens.

Esperamos aproximadamente:

$$C_{j,t} \approx \sum_{i \in j} C_{i,t}$$

A reconstrução utiliza contribuição porque é necessário preservar a direção dos movimentos.

Não podemos reconstruir o item utilizando impacto:

$$\sum_i |C_{i,t}| \neq \left| \sum_i C_{i,t} \right|$$

36. Carregar itens para comparação

```
itens_comparacao = pd.read_sql(
    """
    SELECT
        date,
        categoria,
        categoria_nome,
        indice,
        peso
    FROM bcb.ipca_itens
    ORDER BY date, categoria;
    """,
    engine,
)

itens_comparacao["date"] = pd.to_datetime(
    itens_comparacao["date"]
)

itens_comparacao["categoria"] = (
    itens_comparacao["categoria"]
    .astype(str)
)

itens_comparacao["contribuicao_item"] = (
    itens_comparacao["indice"]
    * itens_comparacao["peso"]
    / 100
)
```

37. Somar contribuições dos subitens

```
contrib_subitens = (
    subitens
    .groupby(
        [
            "date",
            "item_codigo",
```

```
        ],
        as_index=False,
    )["contribuicao"]
    .sum()
    .rename(
        columns={
            "contribuicao":
            "contribuicao_subitens"
        }
    )
)
```

38. Comparar item e soma dos subitens

```
comparacao_hierarquia = (
    itens_comparacao[
        [
            "date",
            "categoria",
            "categoria_nome",
            "contribuicao_item",
        ]
    ]
    .rename(
        columns={
            "categoria":
            "item_codigo",
            "categoria_nome":
            "item_nome",
        }
    )
    .merge(
        contrib_subitens,
        on=[
            "date",
            "item_codigo",
        ],
        how="inner",
        validate="one_to_one",
    )
)

comparacao_hierarquia[
    "erro_reconstrucao"
] = (
    comparacao_hierarquia[
        "contribuicao_subitens"
```

```
    ]
    - comparacao_hierarquia[
        "contribuicao_item"
    ]
)

comparacao_hierarquia[
    "erro_abs"
] = (
    comparacao_hierarquia[
        "erro_reconstrucao"
    ]
    .abs()
)

comparacao_hierarquia.tail(15)
```

	date	item_codigo	item_nome	contribuicao_item	contribuicao_subiter
4065	2026-08-01	5104	Combustíveis (veículos)	-0.0554	-0.0552
4066	2026-08-01	6101	Produtos farmacêuticos	0.0073	0.0073
4067	2026-08-01	6102	Produtos óticos	0.0039	0.0039
4068	2026-08-01	6201	Serviços médicos e dentários	0.0062	0.0062
4069	2026-08-01	6202	Serviços laboratoriais e hospitalares	-0.0009	-0.0009
4070	2026-08-01	6203	Plano de saúde	0.0174	0.0174
4071	2026-08-01	6301	Higiene pessoal	-0.0016	-0.0016
4072	2026-08-01	7101	Serviços pessoais	0.0235	0.0233
4073	2026-08-01	7201	Recreação	-0.0040	-0.0039
4074	2026-08-01	7202	Fumo	0.1133	0.1133
4075	2026-08-01	8101	Cursos regulares	0.0243	0.0242
4076	2026-08-01	8102	Leitura	0.0014	0.0014
4077	2026-08-01	8103	Papelaria	0.0007	0.0007
4078	2026-08-01	8104	Cursos diversos	0.0029	0.0029
4079	2026-08-01	9101	Comunicação	-0.0041	-0.0041

39. Erro de reconstrução

Definimos:

$$\varepsilon_{j,t} = \left(\sum_{i \in j} C_{i,t} \right) - C_{j,t}$$

e:

$$E_{j,t} = |\varepsilon_{j,t}|$$

```
comparacao_hierarquia[
    "erro_reconstrucao"
].describe()
```

```
count   4080.0000
mean       0.0000
std        0.0001
min       -0.0008
25%       -0.0000
50%        0.0000
75%        0.0000
max        0.0007
Name: erro_reconstrucao, dtype: float64
```

40. Maiores erros de reconstrução

```
comparacao_hierarquia.nlargest(
    10,
    "erro_abs",
)[
    [
        "date",
        "item_nome",
        "contribuicao_item",
        "contribuicao_subitens",
        "erro_reconstrucao",
        "erro_abs",
    ]
]
```

	date	item_nome	contribuicao_item	contribuicao_subitens	erro_reconstrucao	er
3044	2024-12-01	Veículo próprio	0.0206	0.0198	-0.0008	0.0
2279	2023-09-01	Veículo próprio	0.0460	0.0453	-0.0007	0.0
800	2021-04-01	Veículo próprio	0.0407	0.0414	0.0007	0.0
1955	2023-03-01	Aluguel e taxas	0.0061	0.0055	-0.0006	0.0
3452	2025-08-01	Veículo próprio	0.0000	0.0006	0.0006	0.0
2993	2024-11-01	Veículo próprio	0.0299	0.0292	-0.0006	0.0
86	2020-02-01	Veículo próprio	0.0224	0.0218	-0.0006	0.0
1259	2022-01-01	Veículo próprio	0.2163	0.2157	-0.0006	0.0
2228	2023-08-01	Veículo próprio	0.0892	0.0886	-0.0006	0.0
1209	2021-12-01	Combustíveis (veículos)	-0.0752	-0.0747	0.0005	0.0

PARTE VII — PRESSÕES HISTÓRICAS

41. Subitem de maior impacto por mês

Para cada mês t:

$$i_t^* = \arg\max_i I_{i,t}$$

identifica o subitem com maior impacto absoluto.

```
idx_maior_impacto = (
    subitens
    .groupby("date")["impacto"]
    .idxmax()
)

maior_impacto_mes = (
    subitens.loc[
        idx_maior_impacto,
        [
            "date",
            "grupo_nome",
            "subgrupo_nome",
            "item_nome",
            "categoria_nome",
            "indice",
            "peso",
            "contribuicao",
            "impacto",
            "direcao",
        ],
    ]
    .sort_values("date")
    .reset_index(drop=True)
)

maior_impacto_mes.tail(12)
```

	date	grupo_nome	subgrupo_nome	item_nome	categoria_nome
68	2025-09-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
69	2025-10-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
70	2025-11-01	Transportes	Transportes	Transporte público	Passagem aérea
71	2025-12-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
72	2026-01-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
73	2026-02-01	Educação	Cursos, leitura e papelaria	Cursos regulares	Ensino fundamental
74	2026-03-01	Transportes	Transportes	Combustíveis (veículos)	Gasolina
75	2026-04-01	Transportes	Transportes	Transporte público	Passagem aérea

	date	grupo_nome	subgrupo_nome	item_nome	categoria_nome
76	2026-05-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
77	2026-06-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
78	2026-07-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
79	2026-08-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen

42. Subitens que mais vezes lideraram a pressão

```
frequencia_impacto = (
    maior_impacto_mes[
        "categoria_nome"
    ]
    .value_counts()
    .rename("meses")
    .to_frame()
)

frequencia_impacto.head(30)
```

categoria_nome	meses
Energia elétrica residencial	28
Gasolina	22
Passagem aérea	16
Perfume	4
Ensino fundamental	4
Arroz	1
Etanol	1
Plano de saúde	1
Automóvel novo	1
Batata-inglesa	1
Tomate	1

43. Maiores impactos históricos

```
subitens.nlargest(
    10,
    "impacto",
)[
    [
        "date",
        "grupo_nome",
        "subgrupo_nome",
```

```
        "item_nome",
        "categoria_nome",
        "indice",
        "peso",
        "contribuicao",
        "impacto",
        "direcao",
    ]
]
```

	date	grupo_nome	subgrupo_nome	item_nome	categoria_nome
11596	2022-07-01	Transportes	Transportes	Combustíveis (veículos)	Gasolina
11973	2022-08-01	Transportes	Transportes	Combustíveis (veículos)	Gasolina
5564	2021-03-01	Transportes	Transportes	Combustíveis (veículos)	Gasolina
23196	2025-02-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
22819	2025-01-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen
1417	2020-04-01	Transportes	Transportes	Combustíveis (veículos)	Gasolina
8580	2021-11-01	Transportes	Transportes	Combustíveis (veículos)	Gasolina
10088	2022-03-01	Transportes	Transportes	Combustíveis (veículos)	Gasolina
12350	2022-09-01	Transportes	Transportes	Combustíveis (veículos)	Gasolina
25835	2025-09-01	Habitação	Combustíveis e energia	Energia elétrica residencial	Energia elétrica residen

---

PARTE VIII — PERSISTÊNCIA DAS PRESSÕES

44. Por que analisar persistência?

Um choque isolado pode produzir grande impacto em um único mês.

Mas existe uma diferença entre:

```
grande impacto isolado
         e
pressão persistente
```

Para uma primeira aproximação podemos contar quantas vezes cada subitem apareceu entre os maiores impactos.

45. Frequência no Top 20 de impacto

```
def marcar_top_n(grupo, n=20):

    limite = min(
        n,
        len(grupo),
    )

    maiores = (
        grupo
        .nlargest(
            limite,
            "impacto",
        )
        .index
    )

    resultado = pd.Series(
        False,
        index=grupo.index,
    )

    resultado.loc[maiores] = True

    return resultado
```

```
subitens["top20_impacto"] = (
    subitens
    .groupby(
        "date",
        group_keys=False,
    )
    .apply(
        marcar_top_n,
        n=20,
        include_groups=False,
    )
)
```

```
persistencia_top20 = (
    subitens[
        subitens["top20_impacto"]
    ]
    .groupby(
        [
            "categoria",
            "categoria_nome",
        ]
    )
```

```
    .size()
    .rename("meses_top20")
    .reset_index()
    .sort_values(
        "meses_top20",
        ascending=False,
    )
)

persistencia_top20.head(20)
```

	categoria	categoria_nome	meses_top20
61	5104001	Gasolina	75
53	5101010	Passagem aérea	73
69	6203001	Plano de saúde	72
41	2202003	Energia elétrica residencial	65
34	1201001	Refeição	56
2	1103003	Batata-inglesa	56
3	1103028	Tomate	55
27	1111004	Leite longa vida	53
72	6301011	Perfume	49
35	1201003	Lanche	47
36	2101001	Aluguel residencial	46
57	5102005	Seguro voluntário de veículo	44
62	5104002	Etanol	44
4	1103043	Cebola	43
55	5102001	Automóvel novo	43
58	5102011	Conserto de automóvel	38
0	1101002	Arroz	34
74	7101010	Empregado doméstico	29
37	2101002	Condomínio	29
40	2201004	Gás de botijão	27

Interpretação

Um componente com grande impacto histórico máximo pode representar apenas um choque isolado.

Já um componente que aparece repetidamente entre os maiores impactos pode representar uma pressão mais persistente.

Portanto:

- impacto máximo → intensidade extrema
- frequência no Top N → persistência/relevância recorrente

PARTE IX — REPRESENTAÇÕES ANALÍTICAS

46. Formato longo

```
subitens_analitico = subitens[
    [
        "date",
        "grupo_codigo",
        "grupo_nome",
        "subgrupo_codigo",
        "subgrupo_nome",
        "item_codigo",
        "item_nome",
        "categoria",
        "categoria_nome",
        "indice",
        "peso",
        "contribuicao",
        "impacto",
        "direcao",
    ]
].copy()

subitens_analitico.tail(10)
```

	date	grupo_codigo	grupo_nome	subgrupo_codigo	subgrupo_nome	item_codigo
30150	2026-08-01	8	Educação	81	Cursos, leitura e papelaria	8104
30151	2026-08-01	8	Educação	81	Cursos, leitura e papelaria	8104
30152	2026-08-01	9	Comunicação	91	Comunicação	9101
30153	2026-08-01	9	Comunicação	91	Comunicação	9101
30154	2026-08-01	9	Comunicação	91	Comunicação	9101
30155	2026-08-01	9	Comunicação	91	Comunicação	9101
30156	2026-08-01	9	Comunicação	91	Comunicação	9101
30157	2026-08-01	9	Comunicação	91	Comunicação	9101
30158	2026-08-01	9	Comunicação	91	Comunicação	9101
30159	2026-08-01	9	Comunicação	91	Comunicação	9101

47. Matriz de variações

A matriz abaixo pode possuir grande número de colunas.

Ela é útil para análise, mas não significa que todos os subitens devam ser utilizados diretamente como features.

```
subitens["subitem_label"] = (
    subitens["categoria"]
    + " - "
    + subitens["categoria_nome"]
)
```

```
indice_pivot = (
    subitens
    .pivot(
        index="date",
        columns="subitem_label",
        values="indice",
    )
    .sort_index()
)

indice_pivot.tail(12)
```

subitem_label date	1101002 - Arroz	1101051 - Feijão - mulatinho
2025-09-01	-2.1400	-5.6100
2025-10-01	-2.4900	-1.2100
2025-11-01	-2.8600	-5.3200
2025-12-01	-2.0400	-2.0700
2026-01-01	-1.5500	0.3800
2026-02-01	-2.3600	3.9900
2026-03-01	-0.3000	4.4200
2026-04-01	2.5300	2.6800
2026-05-01	1.7400	2.2500
2026-06-01	-0.4900	4.1800
2026-07-01	-0.4300	-0.7500
2026-08-01	1.3400	0.1100

48. Matriz de contribuições

```
contribuicao_pivot = (
    subitens
    .pivot(
        index="date",
        columns="subitem_label",
        values="contribuicao",
    )
    .sort_index()
)

contribuicao_pivot.tail(12)
```

subitem_label date	1101002 - Arroz	1101051 - Feijão - mulatinho
2025-09-01	-0.0125	-0.0008
2025-10-01	-0.0141	-0.0002
2025-11-01	-0.0158	-0.0007
2025-12-01	-0.0110	-0.0003
2026-01-01	-0.0081	0.0000
2026-02-01	-0.0121	0.0005
2026-03-01	-0.0015	0.0005
2026-04-01	0.0125	0.0003
2026-05-01	0.0087	0.0003
2026-06-01	-0.0025	0.0005
2026-07-01	-0.0022	-0.0001
2026-08-01	0.0067	0.0000

49. Matriz de impactos

```
impacto_pivot = (
    subitens
    .pivot(
        index="date",
        columns="subitem_label",
        values="impacto",
    )
    .sort_index()
)

impacto_pivot.tail(12)
```

subitem_label date	1101002 - Arroz	1101051 - Feijão - mulatinho
2025-09-01	0.0125	0.0008
2025-10-01	0.0141	0.0002
2025-11-01	0.0158	0.0007
2025-12-01	0.0110	0.0003
2026-01-01	0.0081	0.0000
2026-02-01	0.0121	0.0005
2026-03-01	0.0015	0.0005
2026-04-01	0.0125	0.0003
2026-05-01	0.0087	0.0003
2026-06-01	0.0025	0.0005
2026-07-01	0.0022	0.0001
2026-08-01	0.0067	0.0000

PARTE X — INDICADORES AGREGADOS

50. Construir resumo mensal

No nível de subitens, indicadores agregados podem ser mais úteis para futura modelagem que centenas de séries individuais.

Vamos construir:

- difusão;
- desvio-padrão;
- IQR;
- maior impacto;
- impacto total;
- concentração Top 5;
- concentração Top 10;
- concentração Top 20.

```
estatisticas_mensais = (
    subitens
    .groupby("date")
    .agg(
        media_variacao=(
            "indice",
            "mean",
        ),
        mediana_variacao=(
            "indice",
            "median",
        ),
        desvio_variacao=(
            "indice",
            "std",
        ),
        maior_impacto=(
            "impacto",
            "max",
        ),
        impacto_total=(
            "impacto",
            "sum",
        ),
    )
)
```

```
q1_mensal = (
    subitens
    .groupby("date")["indice"]
    .quantile(0.25)
```

```
)

q3_mensal = (
    subitens
    .groupby("date")["indice"]
    .quantile(0.75)
)

estatisticas_mensais["iqr"] = (
    q3_mensal
    - q1_mensal
)
```

```
indicadores_subitens = (
    estatisticas_mensais
    .join(
        difusao_subitens[
            ["difusao"]
        ]
    )
    .join(
        concentracao
    )
)

indicadores_subitens.tail(12)
```

date	media_variacao	mediana_variacao	desvio_variacao	maior_impacto	impacto_total	iqr	c
2025-09-01	-0.0911	0.0800	3.6956	0.4076	1.1188	1.2800	0
2025-10-01	0.1008	0.0700	2.2723	0.1037	0.6823	1.2400	0
2025-11-01	0.1540	0.1800	2.6042	0.0704	0.8023	1.3600	0
2025-12-01	0.5194	0.2300	2.9230	0.1031	0.9141	1.2500	0
2026-01-01	0.6852	0.3500	3.0575	0.1136	1.1381	1.3500	0
2026-02-01	0.3629	0.3300	2.9347	0.1338	1.1120	1.5400	0
2026-03-01	1.0738	0.4400	3.4419	0.2337	1.1340	1.3800	0
2026-04-01	0.8860	0.5200	3.0284	0.1132	1.1176	1.5900	0
2026-05-01	0.6141	0.3800	4.1719	0.1465	1.0302	1.2400	0
2026-06-01	0.0943	0.0900	2.3664	0.0629	0.6509	1.2300	0
2026-07-01	-0.2222	0.0000	3.4516	0.1288	1.0087	1.1800	0
2026-08-01	-0.0433	0.1300	3.9776	0.3278	1.2264	1.2400	0

51. Estrutura dos indicadores

Podemos representar o estado interno da inflação no mês t por:

$$Z_t = \left[D_t, \sigma_{\pi,t}, IQR_t, I_t^{max}, I_t^{total}, K_{5,t}, K_{10,t}, K_{20,t}\right]$$

Cada medida descreve uma característica diferente do processo inflacionário.

52. O que cada indicador representa?

- D_t Difusão: > Quantos componentes estão apresentando inflação positiva?
- $\sigma_{\pi,t}$ Dispersão: > Quão diferentes são os movimentos de preços?
- IQR_t Dispersão robusta: > Qual a dispersão do centro da distribuição sem depender fortemente > dos extremos?
- I_t^{max} Maior impacto: > Qual foi a maior pressão individual?
- I_t^{total} Soma das magnitudes: > Qual a intensidade total dos movimentos internos?
- $K_{k,t}$ Concentração: > Quanto das pressões está concentrado nos maiores componentes?

PARTE XI — IMPLICAÇÕES PARA MODELAGEM

53. Centenas de séries não significam centenas de boas features

No nível de subitens, poderíamos representar:

$$X_t = [\pi_{1,t}, \pi_{2,t}, \ldots, \pi_{N,t}]$$

Mas esse vetor apresenta desafios:

- alta dimensionalidade;
- correlação;
- mudanças metodológicas;
- entrada e saída de componentes;
- risco elevado de overfitting;
- dificuldade de interpretação.

54. Representação agregada

Uma alternativa é utilizar medidas da estrutura interna:

$$X_t = [IPCA_t, D_t, \sigma_{\pi,t}, IQR_t, I_t^{max}, I_t^{total}, K_{5,t}, K_{10,t}, K_{20,t}]$$

Essas variáveis condensam centenas de componentes em algumas características economicamente interpretáveis.

55. Possíveis sinais futuros

A estrutura granular também permite futuramente criar:

- difusão por grupo;
- difusão por subgrupo;
- impacto de alimentos;
- impacto de combustíveis;
- impacto de serviços;
- persistência dos maiores impactos;
- aceleração da difusão;
- aceleração da concentração;
- número de movimentos extremos;
- proporção do peso em inflação positiva.

Esses indicadores poderão ser mais úteis que a utilização indiscriminada de todos os subitens.

56. Leakage temporal

Para prever a inflação futura:

$$\hat{\pi}_{t+h} = f(X_t)$$

somente informações disponíveis até t poderão entrar em X_t.

Por exemplo:

$$\hat{\pi}_{t+1} = f(\pi_t, D_t, K_{10,t}, I_t^{max}, SELIC_t, ...)$$

pode ser uma estrutura temporalmente válida.

Já utilizar dados dos subitens de $t+1$ para prever o IPCA de $t+1$ constituiria leakage.

---

57. Conclusões

O nível de subitens completa a decomposição hierárquica utilizada neste projeto.

- **Hierarquia**

```
   IPCA
     |
     v
  grupos
     |
     v
subgrupos
     |
     v
   itens
     |
     v
subitens
```

- **Contribuição**

Quando precisamos preservar a direção:

$$C_{i,t} = \pi_{i,t} \frac{w_{i,t}}{100}$$

- **Impacto**

Quando falamos de pressão ou relevância:

$$I_{i,t} = |C_{i,t}|$$

Portanto:

- contribuição → direção
- impacto → pressão em magnitude
- **Difusão**

$$D_t = \frac{\sum_i \mathbf{1}(\pi_{i,t} > 0)}{N_t}$$

mede a abrangência das altas de preços.

- **Concentração**

$$K_{k,t} = \frac{\sum_{i \in TopK_t} I_{i,t}}{\sum_i I_{i,t}}$$

mede quanto dos movimentos está concentrado nos componentes de maior impacto.

- **Dispersão**
  - Medidas como:

$$\sigma_{\pi,t}$$

- e:

$$IQR_t = Q_{0.75,t} - Q_{0.25,t}$$

descrevem a heterogeneidade das variações entre componentes.

Quadro analítico consolidado

Podemos agora caracterizar a inflação em diferentes dimensões:

- nível → Quanto foi o IPCA?
- direção → Quais componentes puxaram para cima ou para baixo?
- impacto → Quais componentes produziram as maiores pressões?
- difusão → Quantos componentes estão subindo?
- concentração → Poucos componentes dominam os movimentos?
- dispersão → Quão diferentes são as variações dos componentes?
- persistência → As principais pressões são recorrentes ou transitórias?

Essa representação é significativamente mais rica que utilizar apenas o IPCA agregado.

- **Próximas etapas**

Com a hierarquia do IPCA analisada:

```
02.ipca
02.01.grupos
02.02.subgrupos
02.03.itens
02.04.subitens
```

o próximo passo não deve ser simplesmente adicionar mais granularidade.

Devemos começar a consolidar:

- indicadores derivados;
- variáveis macroeconômicas;
- defasagens;
- disponibilidade temporal;
- seleção de features;
- definição do target;
- horizonte de previsão;
- estrutura do dataset de machine learning.